

摘要

心血管疾病是全球范围内造成死亡的主要原因之一，其早期筛查和精准诊断对降低疾病死亡率具有重要意义。心电信号（ECG）与胸部 X 光影像（CXR）是心血管疾病诊断的两种重要依据，其中 CXR 是心血管疾病诊断的“黄金标准”，具有丰富的病理细节，但获取需要专业设备，成本较高；ECG 采集简便、成本低廉，更适合大规模筛查，但分类性能较低。因此，如何利用多模态数据协同处理技术，将高性能 CXR 模型的知识迁移至低性能 ECG 模型，从而在缺少 CXR 模态的现实场景下仍能实现高性能的 ECG 智能诊断，是当前面临的核心挑战。

针对上述问题，本文从跨模态知识蒸馏的两个方向出发，提出了两种面向 ECG-CXR 的跨模态知识蒸馏技术。第三章提出了一种基于模型 logits 的跨模态知识蒸馏算法——CMKD-ML，通过引入解耦知识蒸馏和 Kendall 秩相关系数(KRC)，设计了一种基于 KRC 跨模态可靠样本筛选的非目标类知识蒸馏损失函数，从模型输出 logits 层面实现 CXR 教师模型向 ECG 学生模型的知识迁移。第四章提出了一种基于特征对比学习的跨模态知识蒸馏算法——CMKD-FCL，从模型的中间层特征层面出发，融合了三项关键技术：一是采用自适应难负样本惩罚跨模态全局对比损失 AHNPCMA；二是设计了软匹配后期交互损失 SMLI，通过建立 ECG 信号局部区域与 CXR 图像局部区域之间的多对多匹配关系；三是沿用第三章的 KRC 跨模态高质量可靠样本筛选机制，过滤噪声样本和不可靠样本，保证蒸馏质量。

本文基于 MIMIC-ECG-CXR 数据集进行了全面的实验分析，针对心脏肥大、肺水肿和胸腔积液三个多标签分类任务进行验证。实验结果表明，CMKD-ML 平均 AUROC 达到 0.7751，相比未经蒸馏的 ECG 单模态基线提升了 0.0366；CMKD-FCL 平均 AUROC 达到 0.7807，相比基线提升了 0.0422，两种方法均优于现有最优方法，验证了基于模型 logits 和基于特征对比学习的跨模态知识蒸馏策略在多标签医学诊断任务中的可行性和有效性。

关键词：跨模态知识蒸馏；对比学习；知识迁移；智能医学诊断

Abstract

Cardiovascular disease is one of the leading causes of death in the world, and its early screening and accurate diagnosis are great significant in reducing the mortality rate of the disease. Electrocardiogram (ECG) and Chest X-Ray (CXR) are two important bases for the diagnosis of cardiovascular diseases. Among them, CXR is the "gold standard" for cardiovascular disease diagnosis, which has rich pathological details, but its acquisition requires professional equipment and the cost is relatively high. ECG is easy to collect and has a low cost, making it more suitable for large-scale screening, but its classification performance is lower. Therefore, how to use multimodal data collaborative processing technology to transfer the knowledge of high-performance CXR models to low-performance ECG models, so as to still achieve high-performance ECG intelligent diagnosis in real-world scenarios where CXR is unavailable, is the core challenge currently faced.

To address the above problems, this thesis proposes two cross-modal knowledge distillation techniques for ECG-CXR from two directions of cross-modal knowledge distillation. In Chapter 3, a cross-modal knowledge distillation algorithm based on model logits is proposed — CMKD-ML, which introduces decoupled knowledge distillation and Kendall rank correlation coefficient (KRC), and designs a non-target class knowledge distillation loss function based on KRC cross-modal reliable sample filtering, realizing the knowledge transfer from the CXR teacher model to the ECG student model from the model output logits level. In Chapter 4, a cross-modal knowledge distillation algorithm based on feature contrastive learning is proposed — CMKD-FCL, which starts from the intermediate feature level of the model and integrates three key technologies: first, a cross-modal global contrastive loss AHNPCMA with adaptive hard negative penalty; second, a soft matching late interaction loss SMLI, which establishes a many-to-many matching relationship between local regions of ECG signals and local regions of CXR images; third, the KRC cross-modal high-quality reliable sample filtering mechanism from Chapter 3 is retained to filter out noisy samples and unreliable samples, ensuring distillation quality.

This thesis conducts comprehensive experimental analysis based on the MIMIC-ECG-CXR dataset, and verifies on three multi-label classification tasks: cardiomegaly, edema, and pleural effusion. The experimental results show that CMKD-ML achieves an average AUROC of 0.7751, which is an improvement of

0.0366 over the undistilled ECG single-modal baseline; CMKD-FCL achieves an average AUROC of 0.7807, which is an improvement of 0.0422 over the baseline. Both of two methods outperform the existing best methods, verifying the feasibility and effectiveness of the cross-modal knowledge distillation strategies based on model logits and feature contrastive learning in multi-label medical diagnosis tasks.

Key words: Cross-modal knowledge distillation; Contrastive learning; Knowledge transfer; Intelligent medical diagnosis

目 录

摘 要	I
Abstract	II
目 录	IV
1 绪论	1
1.1 研究背景与意义	1
1.2 面向智能医学诊断的跨模态知识蒸馏技术的国内外研究现状	1
1.3 目前存在的问题及其解决方案	6
1.4 本文主要内容	7
2 数据集与评价指标	10
2.1 引言	10
2.2 MIMIC-ECG-CXR 数据集	10
2.3 时间序列分类任务的评价指标	13
2.4 本章小结	15
3 基于模型 logits 的跨模态知识蒸馏技术	16
3.1 引言	16
3.2 技术基础与研究思路	16
3.3 解耦知识蒸馏技术研究	23
3.4 基于 KRC 的跨模态可靠样本筛选的知识蒸馏算法设计	25
3.5 实验环境设置和实验结果分析	27
3.6 本章小结	31
4 基于特征对比学习的跨模态知识蒸馏技术	33
4.1 引言	33
4.2 技术基础与研究思路	33
4.3 自适应难负样本惩罚的全局特征对比学习方法研究	36
4.4 软匹配后期交互 SMLI 的局部对比学习算法设计	38
4.5 全局与局部对比联合约束的知识蒸馏损失函数设计	40
4.6 实验环境设置和实验结果分析	41
4.7 本章小结	46

5 总结与展望.....	48
5.1 本文主要内容与结论	48
5.2 未来展望	49
参考文献.....	51
致谢	57

1 绪论

1.1 研究背景与意义

心血管疾病是全球范围内造成病亡的主要疾病之一，每年威胁着数百万人的生命与健康。尽管目前医学技术迅速发展，医学仪器日益精密，但心血管疾病仍是一类复杂且致命的健康隐患。因此，对心血管疾病进行早期筛查、精准诊断，能够大大降低疾病的死亡率，对保障人类生命与健康有着重要意义。

在临床诊疗场景中，心音、心电等时序生理信号因其无创、便捷等特点，已成为心血管疾病诊断的重要依据。但在真实的临床诊疗场景中，心血管疾病的诊断往往会涉及多种检查手段。除了心电信号（Electrocardiogram, ECG）外，胸部 X 光影像（Chest X-Ray, CXR）也是诊断心血管疾病的重要依据之一。如心电信号和胸部 X 光等不同来源的异构数据构成的多模态数据，能够提供比单一模态更为全面的病理信息，从而提高诊断的可靠性。

不过，胸部 X 光的获取较为复杂，需要在医院的专业设备下进行采集，检查成本较高；而心电信号的获取简单，采集设备便携，成本更低，更适合早期大规模筛查。因此，如何进一步提高深度学习模型对心电信号的诊断性能仍具有十分重要的意义。

胸部 X 光是心血管疾病诊断的黄金标准，具有丰富的病理细节；但心电信号缺少病理细节，容易受噪声干扰。为此，本研究将聚焦跨模态知识蒸馏技术，通过不同模态数据的交互，从而提高心电信号单模态的智能诊断性能，满足在缺少胸部 X 光这一模态的现实诊断场景下仍能保证高性能的智能诊断需求。

1.2 面向智能医学诊断的跨模态知识蒸馏技术的国内外研究现状

跨模态知识蒸馏由最早的多模态数据融合处理技术演变而来。多模态数据融合处理旨在将文本、图像、一维时序信号等不同来源的异构信息进行统一表征，充分利用不同模态的互补信息，突破单一模态的局限性，从而实现更加全面、鲁棒的深度学习模型。多模态数据融合处理技术现已成为人工智能领域的核心研究方向，最开始由图文场景兴起，渐渐应用于音视频、医学诊断等其他领域。而面对分类性能差异大的不同模态数据，无法进行简单的融合处理，跨模态知识蒸馏技术便因此出现。因此，本节先梳理通用图文场景的多模态数据融合处理技术脉

络，再聚焦医学诊断特定场景，围绕心电信号相关多模态融合处理技术展开综述，再由融合处理技术转到跨模态知识蒸馏技术，最后分析 CXR 信号与 ECG 信号跨模态的研究缺口与技术趋势。

1.2.1 通用图文领域多模态融合处理技术发展脉络

基于图文的多模态学习是早期跨模态构建统一表征和协同处理的奠基方向，其技术的演进为其他专业领域提供了许多可迁移或借鉴的范式。

早期的多模态融合主要以数据级、特征级和决策级为基础框架，不同模态的数据仅进行简单的拼接或加权求和，其建模能力有限，无法精准捕捉不同模态的互补信息与语义关联。随着深度学习和 Transformer^[1]架构的普及，以 Lu 等人(2019)^[2]提出的 ViLBERT 为代表的双编码器框架成为主流，通过图文不同模态并行提取特征的同时，进行交叉注意力计算，实现了边编码边融合的范式。之后，Radford 等人(2021)^[3]提出的 CLIP 则开启了对比学习对齐多模态特征的主流范式，通过大规模的图文预训练，将图文不同模态的特征映射到统一的嵌入高维空间中，具有优异的零样本分类和跨模态检索能力。ALIGN^[4]、FLAVA^[5]等模型则基于前面的研究，进一步扩展数据处理规模与多模态统一建模能力。




图 1-1 双编码器框架

随着图文领域多模态融合处理技术的成熟，这种多模态方式慢慢扩展至其他模态。Guzhov 等人(2021)^[6]则将 CLIP 方法扩展至音频模态，提出了 AudioCLIP 框架；Wu 等人(2022)^[7]提出了 Wav2CLIP，通过冻结并蒸馏 CLIP 的图像编码器来预训练音频编码器，将音频映射到与图像、文本的统一嵌入空间中在音频分类、检索、生成等下游任务上获得了 SOTA 效果；Liu 等人(2025)^[8]的 AG-Fusion 则面向了复杂场景的三维目标检测，提出了一种自适应门控多模态融合方法，显著提升了复杂工业场景下的目标检测鲁棒性。

近年来，随着大语言模型（LLM）技术的成熟，基于大参数的多模态大模型

(MLLM) 也已成为主流研究方向, 通过模态编码器与大语言模型进行级联, 实现图、文、音乃至各种数据存储文件等多模态协同处理, 在多模态数据问答交互取得了重大突破, 如 BLIP-2^[9]、LLaVA^[10]、Qwen3^[11]等。至此, 图文领域已形成了相对成熟的双塔编码结构、对比学习对齐特征、注意力融合细粒度交互的完整技术体系, 为医学场景下的影像、时序生理信号和诊断文本的融合交互提供了核心范式。

1.2.2 智能医学诊断多模态融合处理技术国内外研究现状

临床医疗诊断数据通常呈现出典型的多模态异构特性, 包含了医学影像、时序生理信号、电子病历、化验单、医师诊断文本等, 单一模态难以覆盖生理解剖结构、医学语义等多维度信息。医学场景的多模态融合的核心目标就是整合这些互补的多模态信息, 提高疾病诊断、筛查和预测等任务的准确率和鲁棒性, 已成为医学领域的一个重点关注方向。

医学领域早期的多模态融合以医学影像为主, 通过不同来源的影像, 如计算机断层扫描 (Computed Tomography, CT)、磁共振成像 (Magnetic Resonance Imaging, MRI) 和正电子发射断层显像 (Positron Emission Tomography, PET) 等, 利用 CNN、Transformer^[1]等网络联合处理不同的医学影像, 提高疾病定位和诊断精度^[12]。Bavirisetti 等人 (2017)^[13]提出一种全新的加权平均融合算法, 基于引导滤波与图像统计特性实现脑部 MRI 与 CT 图像的融合。Li 等人 (2021)^[14]提出了一种基于监督的深度学习的多模态医学图像融合方法, 实现了不同医学影像的批量融合, 有效提升了融合细节、清晰度和处理效率。

而近些年来, 医学领域的多模态融合从原来的医学影像开始转向多元化发展, 涵盖了影像、文本和时序生理信号等差异更大的异构模态。Huang 等人 (2021)^[15]提出的 GLoRIA 是这一方向的一项基础性工作, 通过对比学习框架将 CXR 图像与其相应的放射学报告文本对齐, 再通过联合训练视觉和语言编码器, 为多模态学习中如何能够缩小视觉和文本特征之间的差距做出了贡献。Hager 等人 (2023)^[16]通过融合影像数据和结构化临床变量 (如年龄、性别等) 扩展了这一想法, 证明了与仅图像模型相比, 整合含结构化临床变量的表格特征可以增强疾病分类任务的性能。King 等人 (2023)^[17]基于时序信号和文本, 通过采取了不同的方法调整连续的临床测量结果, 该策略提高了用于 ICU 结果预测的学习表示质量, 能够做到即使在没有标签的情况下, 也可以增强对比学习的能力, 从弱配对的数据中提

取有用的监督信息。最近也有一些方法^[18,19]探索细粒度级别的模态对齐，证明了对比学习在对齐电子健康记录（HER）、ECG 和影像等不同输入数据的表示方面的有效性。Vaida 等人（2026）^[20]又提出了一种端到端的推荐框架——CRGANNC-GD 方案，将患者画像和药物类别建模为异质图，并通过图扩散进行表征学习。




图 1-2 双流解耦编码器对比学习范式

受 CLIP^[3]、ALIGN^[4]等双流解耦编码器对比学习范式的启发，这一范式也成为了医学诊断领域的主流方法。有不少研究将这种对比学习范式应用于时序生理信号同源多模态。Han 等人（2023）^[21]提出 MAMIL 框架，将 ECG 信号转化为格兰姆角场（GAF）图像，通过注意力机制实现了跨模态特征自适应融合。Chen 等人（2025）^[22]提出 AimTS 框架，从 ECG 原始信号提取折线图和频率图作为补充信息，构建了同源异构模态对比学习框架，并引入两级原型对比学习，性能更加优异和鲁棒。

也有不少研究聚焦于将双流解耦编码器对比学习范式应用在时序生理信号、医学影像和文本等构成的异构多模态。Zhang 等人（2022）^[23]提出的 ConVIRT 框架首次通过双向对比学习，有效对齐 CXR 和放射学报告文本，为医学影像和文本跨模态对比训练奠定了基础。在此基础上，Wang 等人（2022）^[24]进一步提出了 MedCLIP 模型，通过解耦模态间的配对约束，实现了非配对医学数据的高效训练与表征能力。

至于心血管疾病专类诊断场景下，主要以 ECG、CXR 和 CMR 数据为依据，构建多模态模型，以提升心血管疾病的智能诊断性能。Gao 等人（2024）^[25]的 MEDBind 框架以临床报告文本作为桥梁，提出了边缘模态对比损失，构建了三模

态对比框架。Ding 等人 (2024) [19] 的 ECCL 框架则解释了异构多模态间的深层次的语义关联, 实现了仅输入 ECG 信号就能预测 CMR 三维功能参数。Punyamoorthy 等人 (2025) [26] 新提出的 CroMoTEX, 指出近来少有研究针对 ECG-CXR 进行跨模态研究, 因此针对 ECG-CXR 设计了一种基于对比学习的跨模态知识迁移, 将高性能的 CXR 模态分类知识“注入”到低性能的 ECG 模态, 进而提高单 ECG 模态的分类性能, 能够实现在基层医疗场景下难以获取 CXR 数据的前提下仍能进行高性能智能医疗诊断。

但是 CLIP^[3]、ALIGN^[4]等双流解耦编码器对比学习范式仅局限于样本级的全局语义对齐, 并未考虑局部细粒度上的语义对齐。如图片中的人物属性——衣物颜色、装饰品和动作与文字对应的词语属于共同的语义信息。在图文领域, 已有相关的全局与局部对齐联合优化的策略。Zhong 等人 (2022) [27] 基于感兴趣区域 (ROI) 和注意力机制提出了 RegionCLIP, 利用目标检测网络提取的边界框构建了显式的区域级对齐。Yao 等人 (2022) [28] 的 FILIP 框架则提出了另一种思路, 计算视觉 Token 和文本 Token 间的最大相似度, 无需显示空间对齐。詹等人 (2026) [29] 在将 CLIP^[3] 迁移到行人重识别这一任务上时提出了基于身份与属性感知对齐的文本检索行人方法, 实现了全局与细粒度对比损失联合一致性优化。这些基于细粒度的对比学习范式也为本研究中 ECG 与 CXR 两种模态间构建细粒度对齐提供了技术背景。

1.2.3 跨模态知识蒸馏的国内外研究现状

Punyamoorthy 等人 (2025) [26] 所指出现象——现有的 ECG 分类模型性能普遍弱于 CXR 分类模型, 解决的一种方向则是进行跨模态知识迁移, 将高性能的 CXR 模态分类知识“注入”到低性能的 ECG 模态。这一现象无独有偶, 在其他领域也十分常见, 解决这一问题的经典做法就是进行知识蒸馏。

知识蒸馏 (Knowledge Distillation, KD) 旨在将教师模型中的分类逻辑、特征分布、结构关系等知识迁移到学生模型中, 最早起源于 Hinton 等人 (2015) [30] 提出的软标签与 KL 散度的基础框架, 用于将复杂模型 (教师模型) 的知识迁移到更易于部署的轻量小模型 (学生模型) 上, 在保持轻量化的同时依旧能有较好的性能。Romero 等人 (2015) [31] 受知识蒸馏的启发, 选择利用教师网络的中间层特征图来指导学生网络进行训练, 在显著减少参数量的同时实现了相较于传统的知识蒸馏更优的分类性能。




图 1-3 知识蒸馏框架示意图

随着多模态领域的兴起,研究者将视角放在了跨模态的知识蒸馏(Cross-Modal Knowledge Distillation, CMKD)上。Huo 等人(2024)^[32]提出了 C²KD 跨模态知识蒸馏方法,通过 Kendall 秩相关系数(KRC)筛选软标签对齐样本,并引入代理教师-学生网络进行双向蒸馏,从而解决跨模态的模态不平衡与软标签错位等问题。Zhao 等人(2024)^[33]提出的 SimDistill 通过同构的多模态教师-学生架构实现知识蒸馏,学生网络仅用多视角图像输入通过几何补偿模块学习教师的多模态特征。Li 等人(2025)^[34]通过实验揭示了现有跨模态知识蒸馏方法中的两个关键问题:蒸馏路径选择和知识漂移,并提出了 MST-Distill 方法解决了这些局限,MST-Distill 采用了一种多模态的多样化教师模型集成,结合一个实例级路由网络,以实现自适应和动态蒸馏。Xie 等人(2025)^[35]从信息论的视角,探讨了如何在多模态学习的背景下,将拥有多模态融合特征的教师模型知识有效迁移到单一模态或受限模态的学生模型上,进而提出了 MKD 算法,显著提升了学生模型的泛化能力。

1.3 目前存在的问题及其解决方案

根据前文研究可知,当前基于 ECG-CXR 的多模态融合范式在实际应用中面临以下核心挑战。

1.3.1 模态间固有属性差异明显,语义特征空间存在严重鸿沟

胸部 X 光(CXR)作为心血管疾病诊断的“黄金标准”,具有更为清晰的心脏轮廓、胸腔结构和肺部纹理等丰富的解剖信息,特征较为稳定且语义明确;而心电信号(ECG)为一维时序生理信号,容易受到基线漂移、环境噪声等因素干扰,病理特征较弱,可解释性差,特征稳定性差。两类模态的数据在本质上存在着巨大差异,采用通用的多模态融合策略难以实现单 CXR 模态性能,且参数量大、推

理效率降低,难以实现临床上大规模排查场景。

1.3.2 模态间诊断性能差异巨大,知识传递缺乏有效机制

现有诊断模型普遍呈现 CXR 分类模型性能高、ECG 分类模型性能偏低的性能落差,而在实际临床场景中,ECG 信号往往由于其无创便携、成本低易普及等优势,作为大规模筛查和基层临床诊断的首选方式;CXR 影像虽然有着丰富的病理解剖信息,但是需要在医院场景下采集,且成本高。现有主流方法多以“平等融合、联合建模”的方式为主,不适合这类模态特征差异大、模态性能差异大的异构多模态数据,也缺少针对此类数据的知识迁移机制,难以实现“强带动弱”的单模态性能提升。

1.3.3 全局对比学习范式缺少细粒度语义对齐

受 CLIP^[3]、ALIGN^[4]等双流解耦编码器对比学习范式的影像,现有医学多模态对比学习还大多停留在样本级全局对齐,仅关注 CXR 与 ECG 数据的整体语义关联,未考虑局部关键病理区域的细粒度对齐,可能会丢失高价值的病理细节,导致跨模态对齐不充分。

1.3.4 跨模态噪声和分布影响蒸馏稳定性

ECG 与 CXR 数据之间属于弱配对数据,模态差异大,存在视角不一致、病理信息不对应等特点,且 ECG 信号由于其固有特点,易受到噪声干扰,直接使用经典知识蒸馏会强制对齐不可靠的样本,进而影响跨模态知识蒸馏的效率和稳定性,甚至导致学生模型学到错误知识,导致性能反而下降。

对于以上存在的问题,本文从现有跨模态知识蒸馏的两类方向出发——一是基于模型 logits 的跨模态知识蒸馏,通过两类模态输出的 logits 构建特定的知识蒸馏损失函数,将教师模态的高性能知识有效传递到学生模态中,从而提升学生模态的分类性能;二是基于特征对比学习的跨模态知识蒸馏,通过对两类模态的中间特征构建对比学习对齐其语义特征,并考虑细粒度层次的对齐,使学生模态的中间特征分布向教师模特的中间特征分布靠齐,学习教师模态中的病理语义,从而提升学生模态的分类性能。

1.4 本文主要内容

本文主要研究内容与章节之间的关系一览图如图 1-4 所示。

全文分为 5 章，每章的主要内容如下：

第一章：绪论。主要分析本课题的研究背景与意义，提出目前 ECG-CXR 多模态场景下模态特征差异大、分类性能差异大等问题，分析通过跨模态知识蒸馏技术提升 ECG 单模态分类性能的意义；之后针对面向医学智能诊断的多模态数据处理技术，对国内外研究现状做了详细的分析。

第二章：数据集与评价指标。主要说明本项课题研究实验的前期准备工作，包括数据集的选取、数据预处理和评价指标的选取。首先介绍用于 ECG 和 CXR 跨模态知识蒸馏的多模态数据集——MIMIC-ECG-CXR 数据集，详细阐述其数据清洗、模态对齐和标签标注的完整流程；最后介绍本次研究所使用的时间序列分类任务的常用评价指标及其数学表达。

第三章：基于模型 logits 的跨模态知识蒸馏技术。从模型的 logits 出发，设计了基于模型 logits 的跨模态知识蒸馏技术框架——CMKD-ML。先使用自监督对比学习的方式对 ECG 编码器进行预训练，同时利用分类监督损失对 CXR 编码器进行预训练。在此基础之上，通过引入解耦知识蒸馏和 KRC 相关系数，设计了一种基于 KRC 跨模态可靠样本筛选的非目标类知识蒸馏损失函数，构建了完整的训练框架。最后基于 MIMIC-ECG-CXR 数据集进行了全面的实验分析，

第四章：基于特征对比学习的跨模态知识蒸馏技术。从模型的特征对比学习出发，设计了基于特征对比学习的跨模态知识蒸馏技术——CMKD-FCL。在第三章预训练的基础上，从模型的中间特征层面出发，设计了一种基于特征对比学习的跨模态知识蒸馏损失函数。一是采用自适应难负样本惩罚的监督式跨模态全局对比损失 AHNPCMA，对相似度高但不是正样本对的难负样本赋予更高权重，强化特征区分度；二是设计了软匹配后期交互损失 SMLI，通过建立 ECG 信号局部区域与 CXR 图像局部区域之间的多对多匹配关系，实现细粒度的跨模态局部特征对齐；三是沿用第三章的 KRC 跨模态可靠样本筛选机制，过滤噪声样本和不可靠样本，保证蒸馏质量。最后基于 MIMIC-ECG-CXR 数据集进行了全面的实验分析

第五章：总结与展望。对本次研究设计的两种跨模态知识蒸馏技术进行总结和对比分析，结合现有技术趋势，详细分析本课题未来可能的研究方向和改进策略。




图 1-4 全文组织架构图

2 数据集与评价指标

2.1 引言

本章将说明本项课题研究实验的前期准备工作，包括数据集的选取、数据预处理和评价指标的选取。首先介绍用于 ECG 和 CXR 跨模态知识蒸馏的多模态数据集——MIMIC-ECG-CXR 数据集，详细阐述其数据清洗、模态对齐和标签标注的完整流程；最后介绍本次研究所使用的时间序列分类任务的常用评价指标及其数学表达。

2.2 MIMIC-ECG-CXR 数据集

MIMIC-IV^[36] (Medical Information Mart for Intensive Care IV) 是由麻省理工学院 MIT 计算生理学实验室构建的，是一个大型的免费数据库，包含了来自 Beth Israel Deaconess Medical Center ICU 的 30 万左右病人的各项健康数据，如人口统计数据、生命体征测量数据、实验室检查数据、治疗方案、使用药物、护理人员工作记录、医学影像报告和死亡信息等。

2.2.1 MIMIC-IV-ECG 数据集介绍

MIMIC-IV-ECG 数据集收录了近 16 万病人的 80 万份标准 12 导联心电图记录，每份 ECG 记录时长为 10s，采样频率为 500Hz，包含了正常窦性心律和各类异常心率。

2.2.2 MIMIC-CXR-JPG 数据集介绍

MIMIC-CXR-JPG 是以 MIMIC-IV 数据库为基础而构建的胸部 X 光 (CXR) 医学影像数据集，专注于提供和患者临床信息相关联的 CXR 数据^[37]。数据集包含了超 10 万名住院患者的 45 万份胸部 X 光影像的 JPEG 格式，涉及不同扫描设备和不同投影体位，能够贴合真实临床场景的数据差异特点，适合左心室肥厚、心包积液等心脏病变相关的影像与临床指标相联合的关联研究。




图 2-1 MIMIC-IV-ECG 数据集示例图




图 2-2 胸部 X 光解剖结构




图 2-3 不同投影体位的胸部 X 光示例，左 1 为侧位，左 2 为后前位，右 1 为前后位

2.2.3 MIMIC-ECG-CXR 数据集

现有心血管疾病研究的标准数据集几乎局限于单一模态，如 CPSC2018^[38]、PTB-XL^[39]和 MIMIC-IV-ECG-Text^[36]，缺少 ECG-CXR 配对的时序信号-图像的异构多模态数据集，因此基于 MIMIC-IV 临床数据库构建的 MIMIC-ECG-CXR 数据集应运而生。该数据集通过患者的唯一标识符（`subject_id`），精确匹配 MIMIC-IV-ECG 中的 ECG 信号与 MIMIC-CXR-JPG 中的 CXR 图像，包含了 3.74 万名病人，共计 5.36 万的 ECG-CXR 配对数据。

针对胸部 X 光 CXR 影像，先进行灰度化处理后拓展至 RGB 三通道，再通过中心裁剪去除图像边缘伪影，最后统一调整至 224×224 像素尺寸。针对心电信号 ECG，首先补全信号缺失数值，以 100Hz 的频率对信号重采样并结合临床标注完成基线漂移校正，最后对信号做导联级的归一化处理。本次实验所使用的疾病标签为心脏扩大（Cardiomegaly）、水肿（Edema）和胸腔积液（Pleural Effusion）。



图 2-4 不同心脏疾病的胸部 X 光示例，左 1 为心脏肥大（Cardiomegaly），左 2 为水肿（Edema），右 1 为胸腔积液（Pleural Effusion）

2.3 时间序列分类任务的评价指标

在时间序列分类任务中,分类的准确率(Accuracy)是最广泛采用的评价指标。准确率的计算公式如(2-1)所示。

$$\text{Accuracy} = \frac{N(\text{Pre}=\text{label})}{N(\text{Pre}=\text{label}) + N(\text{Pre} \neq \text{label})} \quad (2-1)$$

但是,分类准确率往往会受到某个多数类的影响,导致“乐观估计”,仅适用于类别十分均衡的场景。如果需要更加全面的评价性能,则需要引入混淆矩阵^[40]。因此,Accuracy又可表示为

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{\text{TP} + \text{FP} + \text{TN} + \text{FN}} \quad (2-2)$$

表 2-1 混淆矩阵表

	正样本	负样本
预测为正样本	真阳例 (True Positives, TP)	假阳例 (False Positives, FP)
预测为负样本	假阴例 (False Negatives, FN)	真阴例 (True Negatives, TN)

由混淆矩阵可衍生出一组互补性的指标,从不同角度反映模型在正负样本上的判别能力,具体指标的定义与数学计算公式如下:

1. 灵敏度 (Sensitivity, Se), 也称为召回率 (Recall), 能够反映模型对正样本的判别能力, 计算方式如(2-3)所示。

$$\text{Se} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2-3)$$

2. 特异度 (Specificity, Spe), 能够反映模型对负样本的判别能力, 计算方式如(2-4)所示。

$$\text{Spe} = \frac{\text{TN}}{\text{TN} + \text{FP}} \quad (2-4)$$

3. 精确率 (Precision, Pre), 能够反映模型预测正样本的能力, 计算方式如(2-5)所示。

$$\text{Pre} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (2-5)$$

4. F1 分数, 是召回率和精确率的调和平均值, 能够同时反映模型的正样本判别能

力和预测正样本的能力，是一项综合指标。计算方式如(2-6)所示。

$$F1 = \frac{2}{\frac{1}{Se} + \frac{1}{Pre}} = \frac{2}{\frac{TP+TN}{TP} + \frac{TP+FP}{TP}} = \frac{2TP}{2TP+TN+FP} \quad (2-6)$$

5. 假阳率 (False Positive Rate, FPR)，能够反映模型将负样本误判为正样本的概率，计算方式如(2-7)所示。

$$FPR = \frac{FP}{TN+FP} \quad (2-7)$$

对于本次研究的多标签分类场景，每个类别都需要进行独立的二分类，且每个类别都存在正负样本不均衡的情况，因此需要一个十分综合的性能指标。对于一个深度学习模型，它的输出为软标签，即输出 $y \in [0,1]$ ，预测标签 $\hat{y}$ 表示如(2-8)所示，因此 F1 分数十分依赖阈值 (threshold) 的选择。

$$\hat{y} = \begin{cases} 0, & y < \text{threshold} \\ 1, & y \geq \text{threshold} \end{cases} \quad (2-8)$$

AUROC 是针对各种阈值设置下的分类问题的性能指标，与阈值的选择无关，更能反映模型的综合性能。AUROC (Area Under ROC Curve) 是 ROC (Receiver Operating Characteristic) 曲线下的面积，能够反映模型的整体排序能力，值越大则模型整体区分正负样本的能力越强，而 ROC 曲线则是以 FPR 为横轴，Se 为纵轴，画出不同阈值下的曲线，如图 2-5 所示。




图 2-5 ROC 曲线示意图




图 2-6 AUROC 示意图

2.4 本章小结

本章主要系统阐述了本次实验所必备的前期准备工作，包括数据集的准备和评价指标的选取。首先，对 ECG 和 CXR 各自的数据集做了简要说明，指出目前缺少 ECG-CXR 配对的数据集，因此选择使用由 MIMIC 数据库中的 MIMIC-IV-ECG 心电时序生理信号与 MIMIC-CXR-JPG 胸部 X 光医学影像为数据源，通过患者的 `subject_id` 构建的 MIMIC-ECG-CXR 多模态 ECG-CXR 配对数据集，能够实现 ECG 与 CXR 跨模态的语义关联，便于接下来的实验展开。最后，介绍了时序分类任务的各项性能评价指标，并指出本次多标签分类任务的适用指标，为后续实验的开展建立了基础支撑。

3 基于模型 logits 的跨模态知识蒸馏技术

3.1 引言

在心脏疾病的智能诊断场景下，基于 ECG 数据的分类模型往往性能较差，基于 CXR 数据的分类模型性能较为突出。因此，选择将 CXR 分类模型作为教师模型，通过跨模态知识蒸馏（CMKD）的方式，将 CXR 分类模型的判别知识传递给 ECG 分类模型。本章设计了一种基于模型 logits 的跨模态知识蒸馏（Cross-Modal Knowledge Distillation Based on Model Logits, CMKD-ML）。

本章的 CMKD-ML 基于 MIMIC-ECG-CXR 数据集上进行了性能验证。实验结果表明，CMKD-ML 成功实现了经过知识蒸馏的单模态 ECG 分类性能超越未进行知识蒸馏的单模态 ECG 分类性能，并且其分类性能优于现有基于 ECG-CXR 的跨模态方法。

3.2 技术基础与研究思路

3.2.1 问题分析与设计思路

由于基于 ECG 数据的分类模型往往性能较差，基于 CXR 数据的分类模型性能较为突出，因此选择将 CXR 分类模型作为教师模型，ECG 分类模型作为学生模型，通过跨模态知识蒸馏（CMKD）的方式，设计一个知识蒸馏传统方法——基于模型 logits 的损失函数，将 CXR 分类模型的判别知识传递给 ECG 分类模型。

在两个模态进行基于模型 logits 交互之前，需要事先准备两个模型——ECG 分类模型和 CXR 分类模型。其中，ECG 分类模型作为学生模型，需要经过预训练，确保其编码器部分具有一定的特征聚合能力，否则会大大降低之后知识蒸馏的过程；CXR 分类模型作为教师模型，同样需要经过预训练，但 CXR 分类模型需要为 ECG 分类模型提高分类判别知识，因此需要具有强大的分类能力，因此需要提前进行分类训练，得到一个分类性能完好的 CXR 分类模型。

为得到具有一定特征聚合能力的 ECG 预训练模型，有两个技术方向：一是与 CXR 分类模型一致，提前进行分类训练，同样得到一个分类性能完好的 ECG 分类模型。但是这么做的风险是，ECG 的特征更加关注自己的特征判别能力，但这种能力相对较弱，其提取的特征可能会受到数据集偏置、噪声或伪相关的影响，不

利于后续接受来自 CXR 的判别知识。二是采用与 SimCLR^[41]一致的自监督的方式，预训练时的编码器更聚焦 ECG 的时序形态、节律和导联相关性等生理信号本质特征，特征鲁棒性更强，便于后续的知识蒸馏。CroMoTEX^[26]方法中提到，采取 SimCLR 方式预训练的 ECG 编码器效果优于直接利用分类训练的 ECG 编码器。因此，本章参照 CroMoTEX^[26]方法，使用自监督对比学习方式对 ECG 编码器进行预训练。

综上所述，基于模型 logits 的跨模态知识蒸馏算法具体实现流程应分为三个步骤：

第一步，确定教师模型和学生模型的编码器，并进行预训练。选择现有性能表现优秀的 ECG 分类模型的编码器和 CXR 分类模型的编码器；之后对 ECG 编码器进行自监督预训练，确保其具有提取 ECG 特征能力；最后，通过有监督方式，对 CXR 分类模型（包含 CXR 编码器和分类头）进行分类任务的预训练，确保其具有强大的分类性能。

第二步，设计基于模型 logits 的跨模态知识蒸馏的损失函数。传统的知识蒸馏损失函数都是基于同模态场景，参数量大的模型作为教师模型，参数量小的模型作为学生模型，直接应用于 ECG-CXR 的跨模态场景时，可能会因模态差异大而导致出现知识传递效率低下、蒸馏效果不强的情况。因此，本章需要针对跨模态的特性，设计一个适用于本次任务的 logits 蒸馏损失函数，其核心是对教师模型（CXR 模型）的 logits 和学生模型（ECG 模型）的 logits 进行对齐约束，确保学生模型在学习自身 ECG 特征的同时，能够有效吸收教师模型 CXR 的判别知识，实现跨模态知识的高效传递。

第三步，综合第一步和第二步，构建 CMKD-ML 整体框架并完成端到端训练。训练过程中冻结教师模型以保证其不被学生模型“拖累”。训练过程中，将 ECG 数据和 CXR 数据分别送入 ECG 分类模型和 CXR 分类模型，得到各自的 logits，进行损失函数计算后梯度反向传播，更新 ECG 分类模型的参数，实现从 CXR 教师模型到 ECG 学生模型的知识迁移。整个训练过程基于 MIMIC-ECG-CXR 数据集，最终得到经过知识蒸馏优化的 ECG 分类模型，实现单模态 ECG 分类性能的提升。

3.2.2 CMKD-ML 算法框架设计




图 3-1 CMKD-ML 框架示意图

CMKD-ML 整体框架分为两部分——一是对 ECG 和 CXR 两类模态的编码器进行预训练；二是在经过预训练的编码器的基础上，对两类分类模型输出的 logits 构建特有的跨模态知识蒸馏损失函数。

ECG 编码器主要包含两个部分，一是 Patch Embedding 部分，使用的是 MoRE^[18] 同样的框架；二是 Transformer Encoder 部分，参考了 CroMoTEX^[26] 的结构。具体结构见图 3-2。

CXR 编码器是经 torchxrayvision^[42] 预训练的 DenseNet-121。具体结构见图 3-3。




图 3-2 ECG 编码器结构




图 3-3 CXR 编码器结构

3.2.2.1 预训练阶段

首先，对 ECG 编码器进行预训练。预训练的方式是，一个 ECG 数据经过不同的增强变换后，分别送入 ECG 编码器编码，再经过一个映射头投影为两个特征，这两个特征是相似的，因此他们的相似度需要越小越好；而这两个特征与同一个批次的其他 ECG 数据应该是不同的，因此他们的相似度需要越大越好。这正是

SimCLR^[41]的做法。

SimCLR^[41]是一个用于视觉表征对比学习的框架，采用了一种自监督的对比学习方式，通过潜在空间中的对比损失，最大化同一数据实例的不同增强视图之间的相似性，而最小化不同数据实例的增强视图间的相似性，进而学习到数据的表征。具体的操作流程如图 3-4 所示。




图 3-4 SimCLR 自监督对比学习框架示意图




图 3-5 ECG 编码器预训练过程

因此，ECG 编码器的自监督对比学习流程如图 3-5 所示。一个批次大小为 B 的 ECG 数据 $\{E_1, E_2, E_3, \dots, E_B\}$ 先经过基于 Vector-Cardiogram^[43] (VCG-based) 数据增强方法，得到增强视图 $\{[V_1^{\text{view1}}, V_1^{\text{view2}}], [V_2^{\text{view1}}, V_2^{\text{view2}}], [V_3^{\text{view1}}, V_3^{\text{view2}}], \dots\}$ 。再由 ECG Encoder 编码和映射头 Proj (见图 3-6) 投影后得到统一特征空间中的 ECG 数据特征 $\{[F_1^{\text{view1}}, F_1^{\text{view2}}], [F_2^{\text{view1}}, F_2^{\text{view2}}], [F_3^{\text{view1}}, F_3^{\text{view2}}], \dots\}$ 。最后计算 Info-NCE^[44] 损失函数后反向梯度传播更新参数，Info-NCE 损失函数具体计算方式如(3-1)所示。

$$\begin{aligned} \text{sim}(\mathbf{u}, \mathbf{v}) &= \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \\ \ell_{i,j} &= -\log \frac{\exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_j) / \tau)}{\sum_{k=1}^{2N} \mathbf{1}_{[k \neq i]} \exp(\text{sim}(\mathbf{z}_i, \mathbf{z}_k) / \tau)} \\ \mathcal{L}_{\text{Info-NCE}} &= \frac{1}{2N} \sum_{k=1}^N [\ell(2k-1, 2k) + \ell(2k, 2k-1)] \end{aligned} \quad (3-1)$$

最后，对 CXR 分类模型（CXR 编码器+MLP 分类头）进行预训练。预训练的方式是，直接利用多标签分类损失训练，从而得到具有分类能力的 CXR 分类模型。MLP 分类头结构见图 3-7。




图 3-6 映射头 Proj 结构




图 3-7 分类头 MLP 结构

3.2.2.2 模型 logits 构建跨模态知识蒸馏

在基于前文得到的 ECG 和 CXR 两个模态的编码器后，进入第二个训练阶段——基于模型 logits 的跨模态知识蒸馏。

将 CXR 模态的编码器和分类头进行参数冻结，作为教师模型；将 ECG 模型的编码器和分类头加入参数的训练，作为学生模型。由 MIMIC-ECG-CXR 多模态 ECG-CXR 配对数据集获得每一批次配对的 ECG-CXR 数据，分别经各自的编码器和分类头后得到最终输出的 logits，使用基于 KRC 跨模态可靠样本筛选的非目标类知识蒸馏损失函数后进行梯度的反向传播，更新 ECG 模态的编码器和分类头。




图 3-8 模型 logits 构建跨模态知识蒸馏示意图

3.3 解耦知识蒸馏技术研究

在多模态知识蒸馏中，损失函数的设计将直接决定模型提取跨模态知识的能力，进而影响最后的分类性能。CMKD-ML 以经典知识蒸馏损失函数出发，结合“解耦知识蒸馏 (DKD)”与“肯德尔秩相关系数 (KRC)”的优势，针对多标签分类的跨模态知识蒸馏场景，设计了一个解耦自适应的损失函数 $\mathcal{L}_{Logits}$ ，从而实现 ECG 学生模型分类性能的上升。

3.3.1 经典知识蒸馏损失函数

设 T 为教师模型， S 为学生模型。根据经典知识蒸馏损失函数，为平滑模型的输出分布，缓解硬标签监督带来的梯度震荡和过拟合风险，稳定传递暗知识^[30]，教师模型输出 I^T 和学生模型输出 I^S 先经过 Sigmoid 函数转化为类别概率分布，并

引入温度系数 $\tau (\tau > 1)$ 对输出 logits 进行软化处理, 具体计算方式如(3-2)所示。

$$\begin{aligned}\hat{y}^T &= \text{Sigmoid}(l^T / \tau) \\ \hat{y}^S &= \text{Sigmoid}(l^S / \tau)\end{aligned}\quad (3-2)$$

其中, $\text{Sigmoid}(\cdot)$ 为 Sigmoid 激活函数, 温度系数 τ 越高, 输出分布越平滑, 暗知识保留越完整^[30]。

KL 散度用于衡量两个概率分布 P 和 Q 之间的差异程度, 其计算方式为 $D_{KL}(P \| Q) = \sum_k P_k \log \frac{P_k}{Q_k}$ 。基于 KL 散度衡量教师和学生模型输出概率分布的差异, 经典知识蒸馏损失函数 KD Loss 定义如(3-3)所示。其中, $D_{KL}(\hat{y}^T \| \hat{y}^S)$ 为 $\hat{y}^T$ 和 $\hat{y}^S$ 之间的 KL 散度, 具体计算方式如(3-4)所示, $\mathcal{L}_{CE}$ 为学生模态的分类损失, 具体计算方式如(3-5)所示, 其中 y 为真实标签。这样, 学生模态将会一方面根据分类真实标签调整自身概率分布, 另一方面逼近教师模态的概率分布。但经典知识蒸馏损失函数并未区分目标类和非目标类知识, 也未考虑存在跨模态噪声影响的不可靠样本。

$$\text{KD}(\hat{y}^T, \hat{y}^S) = D_{KL}(\hat{y}^T \| \hat{y}^S) + \mathcal{L}_{CE} \quad (3-3)$$

$$\begin{aligned}D_{KL}(\hat{y}^T \| \hat{y}^S) &= \sum_i \hat{y}_i^T \log \frac{\hat{y}_i^T}{\hat{y}_i^S} \\ &= \underbrace{\sum_i \hat{y}_i^T \log \hat{y}_i^T}_{=\text{Const when } T \text{ is frozen}} - \sum_i \hat{y}_i^T \log \hat{y}_i^S\end{aligned}\quad (3-4)$$

$$\mathcal{L}_{CE} = -\sum_i y_i \log(\text{sigmoid}(l_i^S)) \quad (3-5)$$

3.3.2 解耦知识蒸馏

解耦知识蒸馏 (Decoupled Knowledge Distillation: DKD)^[45] 已证明, 教师模型与学生模型之间的 KL 散度分解为两个部分: 目标类知识蒸馏 (TCKD) 和非目标类知识蒸馏 (NCKD), 只有应用 NCKD 才能获得与经典 KD 相当甚至更好的结果, 同时降低冗余监督, 提高训练的稳定性。

本章将 DKD 思想扩展至本次的多标签分类任务场景。下面推导多标签分类任务的 TCKD 和 NCKD。

设样本 i 共有 C 个类别, 真实标签 $y_i = [y_{i,1}, y_{i,2}, \dots, y_{i,C}]$, 其中

$y_{i,c} \in \{0,1\} (c=1,2,\dots,C)$ (1 代表正样本, 0 代表负样本)。模型输出的后验概率 $\hat{y}_i = [\hat{y}_{i,1}, \hat{y}_{i,2}, \dots, \hat{y}_{i,C}]$, $\hat{y}_{i,c} \in [0,1] (c=1,2,\dots,C)$ 。设样本 i 在其中 $m (0 \leq m \leq C)$ 个类别上为正样本, 其余类别上为负样本, 则称所有类别构成全类别集合 $C(i) = \{1,2,\dots,C\}$, 正样本类别属于目标类集合 $T(i)$, 负样本类别属于非目标类集合 $N(i) = C(i) \setminus T(i)$ 。设 T 为教师模型, S 为学生模型, 则

$$\begin{aligned}
 D_{\text{KL}}(\hat{y}^T \parallel \hat{y}^S) &= \sum_i \sum_c \hat{y}_{i,c}^T \log \frac{\hat{y}_{i,c}^T}{\hat{y}_{i,c}^S} \\
 &= \underbrace{\sum_i \sum_{c \in T(i)} \hat{y}_{i,c}^T \log \frac{\hat{y}_{i,c}^T}{\hat{y}_{i,c}^S}}_{\text{TCKD}} + \underbrace{\sum_i \sum_{c \in N(i)} \hat{y}_{i,c}^T \log \frac{\hat{y}_{i,c}^T}{\hat{y}_{i,c}^S}}_{\text{NCKD}}
 \end{aligned} \quad (3-6)$$




图 3-9 多标签分类的解耦知识蒸馏

3.4 基于 KRC 的跨模态可靠样本筛选的知识蒸馏算法设计

3.4.1 基于 KRC 的跨模态可靠样本筛选

肯德尔相关系数 (Kendall rank correlation coefficient) [46], 又叫 Kendall's tau, 是数学统计中一个常用的系数, 用来描述两个序列的相关系数。如果两个序列完全一致, 则肯德尔相关系数值为 1, 两个毫不相关的序列的肯德尔相关系数值为 0, 而两个互逆的序列的肯德尔相关系数值为 -1。

$C^2KD^{[32]}$ 中已通过实验证明, 肯德尔相关系数 (KRC) 结合非目标类知识蒸馏 (NCKD) 在跨模态知识蒸馏中的表现优于经典的 KD 损失——KL 散度。传统 KD

不管样本是否可靠，全部强制蒸馏；而 KRC 系数能保证只在“教师与学生预测趋势一致”的样本上做蒸馏，过滤噪声、冲突、不可靠样本。

样本 i 的 KRC 系数计算方式如(3-7)所示，由 KRC 系数得到的掩码系数 η 如(3-8)所示。

$$\text{KRC}(\hat{y}_i^S, \hat{y}_i^T) = \frac{2}{C(C-1)} \sum_{c_1 < c_2} \text{sign}(\hat{y}_{c_1}^S - \hat{y}_{c_2}^S) \cdot \text{sign}(\hat{y}_{c_1}^T - \hat{y}_{c_2}^T) \quad (3-7)$$

$$\eta_i = \begin{cases} 1, & \text{KRC}(\hat{y}_i^S, \hat{y}_i^T) > \omega \\ 0, & \text{otherwise} \end{cases} \quad (3-8)$$




图 3-10 KRC 筛选机制

3.4.2 基于 KRC 跨模态可靠样本筛选的非目标类知识蒸馏损失函数

本章基于 KRC 系数的跨模态非目标类知识蒸馏 CM-NCKD，并结合学生模态的分类交叉熵损失，设计了一种跨模态分类损失 $\mathcal{L}_{\text{Logits}}$ ，如(3-9)所示。

$$\mathcal{L}_{\text{Logits}} = \lambda \mathcal{L}_{\text{CM-NCKD}} + \mathcal{L}_{\text{CE}} \quad (3-9)$$

其中， $\mathcal{L}_{\text{CM-NCKD}}$ 的计算方式如(3-10)所示， $\mathcal{L}_{\text{CE}}$ 的计算方式如(3-11)所示。

$$\mathcal{L}_{\text{CM-NCKD}} = -\sum_i \left(\eta_i \sum_{c \in N(i)} \hat{y}_{i,c}^T \log \hat{y}_{i,c}^S \right) \quad (3-10)$$

$$\mathcal{L}_{\text{CE}} = -\sum_i \sum_c y_{i,c} \log(\text{Sigmoid}(l_{i,c}^S)) \quad (3-11)$$

最终损失函数的计算方式如(3-12)所示。

$$\begin{aligned} \mathcal{L}_{\text{total}} &= \mathcal{L}_{\text{Logits}} \\ &= \lambda \mathcal{L}_{\text{CM-NCKD}} + \mathcal{L}_{\text{CE}} \end{aligned} \quad (3-12)$$




图 3-11 损失函数计算流程图

3.5 实验环境设置和实验结果分析

3.5.1 实验环境设置

本章实验均基于 PyTorch 框架^[47]实现,实验环境设置如表 3-1 所示。CMKD-ML 训练时的参数设置如表 3-2 所示,训练过程分为两个阶段,均采用 AdamW^[48]优化器计算学习率。预训练阶段过程中,ECG 编码器初始学习率为 $4e-6$,共训练了 40 个 epoch,采用了 5 轮预热和余弦衰减策略,batch size 为 512; CXR 编码器初始学习率为 $1e-4$,共训练了 8 个 epoch,采用了 10 轮预热加余弦衰减测量了,batch size 为 64。在最后的 CMKD-ML 跨模态蒸馏阶段,初始学习率为 $1e-4$,共训练了 8 个 epoch,采用了 5 轮预热和余弦衰减策略,batch size 为 64。

表 3-1 CMKD-ML 软硬件环境

名称	信息	个数
CPU	英特尔 Xeon Gold 6330@2.0GHz 28 核心, 56 线程	1
GPU	英伟达 RTX3080Ti 12G GDDR6X	1

名称	信息	个数
内存	镁光 MICRON 64GB DDR4 2933	4
操作系统	Ubuntu 18.04	/
编程语言	python 3.12.13	/
深度学习框架	pytorch 2.10.0+ CUDA13.0	/

表 3-2 CMKD-ML 训练相关参数设置

阶段	名称	设置值	
预训练阶段		ECG 编码器	CXR 编码器
	优化器	AdamW	AdamW
	初始学习率	4e-6	1e-4
	训练轮次	40	14
	学习策略	5 轮预热+余弦衰减	10 轮预热+余弦衰减
	学习率衰减系数	0.5	
	Batch size	512	64
CMKD-ML 阶段	优化器	AdamW	
	初始学习率	1e-4	
	训练轮次	8	
	学习策略	5 轮预热+余弦衰减	
	学习率衰减系数	0.5	
	Batch size	64	

CMKD-ML 损失函数中的超参数设置如表 3-3 所示。

表 3-3 CMKD-ML 损失函数超参数设置

损失函数	公式	参数	值
Logits 温度软化	(3-2)	τ	2.0
KRC 系数	(3-8)	ω	0
最终损失函数	(3-12)	λ	0.1

3.5.2 实验结果分析

本章的实验结果分析中的性能指标均使用的是 AUROC。

3.5.2.1 对比实验分析

表 3-4 CMKD-ML 对比实验结果

	心脏肥大	肺水肿	胸腔积液	Average
ECG_only	0.7271	0.7632	0.7252	0.7385
ResNet-1D	0.7065	0.6842	0.6351	0.6753
ECCL ^[19]	0.7085	0.6787	0.6412	0.6761
BIOT ^[49]	0.7263	0.6945	0.6023	0.6744
SupCon ^[50]	0.7446	0.7764	0.7081	0.7430
Cro-AE ^[51]	0.7215	0.6826	0.6608	0.6883
CroMoTEX ^[26]	0.7516	0.7671	0.7331	0.7506
CMKD-ML	0.7582	0.7999	0.7672	0.7751
	↑ 0.0311	↑ 0.0367	↑ 0.0420	↑ 0.0366
CXR_only	0.8657	0.9231	0.9109	0.8999

为更加全面地评估 CMKD-ML 的性能水平，本章通过与现有的方法进行的全类别的对比分析，包括仅单模态 ECG 方法、自监督对比训练方法和跨模态训练方法，同时给出了 CXR 单模态能力作为参考标准，结果如表 3-4 所示。

CMKD-ML 平均 AUROC 数值为 0.7751，ECG_only 基线平均 AUROC 为 0.7385，CMKD-ML 指标上涨了 0.0366。依托 CXR 教师模型的特征信息迁移，ECG 学生模型的病症分类表现在三个类别上均得到了明显改善，本章的跨模态知识蒸馏方式实现了有效强化单模态模型判别能力。

与主流的自监督学习方案，平均 AUROC 区间集中在 0.6744 至 0.7430。本章的 CMKD-ML 整体表现优于上述各类方法，相较于自监督方案中综合表现最佳的 SupCon^[50]，平均 AUROC 高出了 0.0321。仅依托 ECG 单一模态开展自监督学习，难以充分挖掘数据内部有效判别特征。融入跨模态信息并完成知识迁移，能够有效弥补单模态学习的局限性，进一步提升模型综合性能。

而对比跨模态研究方案 CroMoTEX^[26]，CMKD-ML 在三个类别的诊断任务上分别实现 0.0066、0.0328、0.0341 的性能提升，整体平均 AUC 增加 0.0245，达到了现有方法最优性能。

CXR_only 模型平均 AUROC 为 0.8999，CMKD-ML 平均 AUROC 为 0.7751，

二者存在 0.1248 的性能差值。客观来看, ECG 模态的分析能力仍与 CXR 模态存在差距。经过跨模态知识蒸馏优化后, ECG 模型分类精度已满足实际使用需求。结合临床场景分析, ECG 信号采集流程简便、获取成本更低, 优化后的 ECG 分析模型更贴合基层医疗与大规模筛查场景, 具备良好的落地应用价值。

3.5.2.2 消融实验分析

为验证 CMKD-ML 中使用解耦知识蒸馏的 NCKD 就能够达到经典 KD 损失的效果和 KRC 系数样本筛选机制的贡献作用, 本章设计了消融实验, 分别验证 NCKD 和 KRC 的作用。

表 3-5 CMKD-ML 消融实验结果

	心脏肥大	肺水肿	胸腔积液	Average
CMKD-ML				
(no NCKD, no KRC)	0.7563	0.7943	0.7611	0.7706
CMKD-ML				
(no KRC)	0.7561	0.7955	0.7607	0.7707
CMKD-ML	0.7582	0.7999	0.7672	0.7751

对比表 3-5 中的 CMKD-ML(no NCKD, no KRC)和 CMKD-ML (no KRC)可知, 使用 NCKD 损失结合监督分类损失完全能够实现使用完整的 KD 损失再结合监督分类损失的效果, 每个类别的 AUROC 性能相差均可忽略不计, 这证明了在本研究的多标签分类任务上, 解耦知识蒸馏也是成立的, 即使用 NCKD 损失就可达到经典的 KD 损失。

再对比表 3-5 中的 CMKD-ML(no KRC)和 CMKD-ML 可知, 使用了 KRC 样本筛选机制后, 完整模型在心脏肥大类别上提升 0.0021, 在肺水肿类别上提升 0.0044, 在胸腔积液类别上提升 0.0065, 平均 AUROC 从 0.7707 提升至 0.7751, 提升了 0.0044。引入 KRC 机制计算教师模型和学生模型的 logits 相关性, 可筛选出两个模型预测趋势一致的高质量、高可靠的样本进行蒸馏, 可过滤噪声样本和跨模态不可靠样本, 在一定程度上可以避免直接强制性蒸馏带来的负面效果。

3.5.2.3 特征分布可视化分析

为直观展示 CMKD-ML 蒸馏后 ECG 模型的特征表征能力, 本章采用 UMAP^[52]降维方法对测试集样本的中间层特征进行可视化分析。分别针对心脏肥大、肺水

肿和胸腔积液三个诊断类别，将正样本和负样本的特征投影至二维空间进行展示。

可视化结果表明，经过 CMKD-ML 跨模态知识蒸馏后，ECG 模型在三个诊断类别上均能学到具有一定区分度的特征表征。正样本和负样本在嵌入空间中呈现出一定程度的分离趋势，说明模型已从 CXR 教师模型中有效迁移了判别性知识，使得 ECG 学生模型的特征空间具备了较好的类别区分能力。




图 3-12 心脏肥大类别的 UMAP 特征图展示（从左往右依次为单模态 ECG、经 CMKD-ML 蒸馏后的 ECG 和单模态 CXR）




图 3-13 肺水肿类别的 UMAP 特征图展示（从左往右依次为单模态 ECG、经 CMKD-ML 蒸馏后的 ECG 和单模态 CXR）




图 3-14 胸腔积液类别的 UMAP 特征图展示（从左往右依次为单模态 ECG、经 CMKD-ML 蒸馏后的 ECG 和单模态 CXR）

3.6 本章小结

本章针对心脏疾病智能诊断场景中 ECG 单模态分类性能不足的问题，提出了一种基于模型 logits 的跨模态知识蒸馏算法——CMKD-ML，实现了通过将性能更

优异的 CXR 模型作为教师模型，将丰富的病理细节和判别知识迁移至学生模型 ECG 模态中，最终实现了 ECG 单模态分类性能的大幅提升。

在算法设计方面，本章先使用自监督对比学习的方式对 ECG 编码器进行预训练，同时利用分类监督损失对 CXR 编码器进行预训练。在此基础上，本章在跨模态知识蒸馏阶段通过引入解耦知识蒸馏和 KRC 相关系数，设计了一种基于 KRC 跨模态可靠样本筛选的非目标类知识蒸馏损失函数，构建了完整的训练框架。

在实验结果方面，本章基于 MIMIC-ECG-CXR 数据集进行了全面的实验分析，包括消融实验分析和对比实验分析。消融实验表明了使用解耦知识蒸馏的 NCKD 部分就可达到传统知识整理损失的性能，且 KRC 可靠样本筛选能够为最终模型带来一定的性能提升。对比实验则表明了 CMKD-ML 在心脏肥大、肺水肿和胸腔积液三个类别上均优于现有方法，且相比现有最优的跨模态方法 CroMoTEX^[26]的平均 AUROC 提升了 0.0245，相比未经蒸馏的 ECG 单模态基线提升了 0.0366。

综上所述，CMKD-ML 算法成功实现了从 CXR 教师模型到 ECG 学生模型的高效跨模态知识迁移，有效提升了 ECG 单模态分类性能，验证了基于模型 logits 的跨模态知识蒸馏策略在多标签医学诊断任务中的可行性和有效性。

4 基于特征对比学习的跨模态知识蒸馏技术

4.1 引言

本章在第三章的预训练基础上,从模型的中间特征层面出发,设计了一种基于特定对比学习的跨模态知识蒸馏(Cross-Modal Knowledge Distillation Based on Features Contrastive Learning, CMKD-FCL)。

本章的 CMKD-FCL 基于 MIMIC-ECG-CXR 数据集上进行了性能验证。实验结果表明,CMKD-FCL 成功实现了经过知识蒸馏的单模态 ECG 分类性能超越未进行知识蒸馏的单模态 ECG 分类性能,并且其分类性能优于现有基于 ECG-CXR 的跨模态方法。

4.2 技术基础与研究思路

本节围绕多模态对比学习的理论基础、特征级的知识蒸馏技术系统阐述本章 CMKD-FCL 的技术基础与设计思路,最后介绍 CMKD-FCL 整体框架的设计。

4.2.1 多模态对比学习的理论基础

对比学习的核心目标就是将原始数据提取到的高维特征映射到一个统一共享的嵌入空间中,在这一空间中通过拉近正样本对、远离负样本对学习到通用的判别性和高泛化的表征。其理论基础为互信息最大化^[53]和超球面对齐-均匀性准则^[54],即要求正样本对的特征在超球面上彼此靠近,且所有数据的特征尽可能均匀地分布在单位超球面上,最大化保留信息,负样本对的特征则在超球面上彼此远离,以最大化互信息。Info-NCE 作为对比学习的标准损失函数,由 Oord 等人(2018)^[44]提出,为单模态与多模态的对比学习提供了统一的数学表达形式。

多模态对比学习就是将上述理论基础扩展至异构多模态数据,将同一语义的不同模态数据视为正样本对,在共享的嵌入空间中进行跨模态对齐。Radford 等人(2021)^[3]提出的 CLIP 模型通过大规模图像-文本对比预训练实现了强泛化能力和 Zero-Shot 能力,成为后续多模态对比学习的基准范式。

Khosla 等人(2020)^[50]则提出了监督对比学习 SupCon,在对比学习目标函数中引入类别标签可以使得同类样本在嵌入空间中形成更加紧凑的聚类,从而提升对比学习的效果。

4.2.2 特征级的知识蒸馏技术

传统知识蒸馏以 Hinton^[30]等人提出的 logits 软标签蒸馏为准则,正如第三章提到的。之后的研究学者将目光聚焦到模型的中间层特征,提出了特征级知识蒸馏 (Feature-based Knowledge Distillation),直接以模型的中间层特征为知识载体,希望学生模型的特征逼近教师模型的特征,可全面地迁移高层语义和结构信息,在某些复杂任务和跨模态场景下更加稳定有效。

特征级知识蒸馏的开创是 Romero 等人 (2015)^[31]提出的 FitNets 框架,首次引入 Hint 层机制,希望学生模型的中间层特征向教师模型对应的中间层特征对齐靠近,能够提高特征学习能力和泛化能力。Liu 等人 (2024)^[55]针对语义分割任务进一步改进 FitNet 特征蒸馏方法,提出了一种角度蒸馏方式,可以不受特征幅值影响。

在 ECG-CXR 这一模态差异显著的异构模任务中,本章通过实验也证明最终以特征对比形式的知识蒸馏优于第三章提出的基于模型 logits 的知识蒸馏效果。

综上所述,基于特征对比学习的跨模态知识蒸馏算法具体实现流程应分为三个步骤:

第一步,确定教师模型和学生模型的编码器,并进行预训练。这部分与第三章保持一致。

第二步,设计基于特征对比学习的跨模态知识蒸馏的损失函数。本章从特征对比学习的层面出发,针对跨模态的特性,设计一个适用于本次任务的特征对齐和分类性能联合优化的损失函数,其核心是对教师模型 (CXR 模型) 的中间层特征和学生模型 (ECG 模型) 的中间层特征进行对齐约束,确保学生模型在学习自身 ECG 特征的同时,能够有效吸收教师模型 CXR 的判别知识,实现跨模态知识的高效传递。

第三步,综合第一步和第二步,构建 CMKD-FCL 整体框架并完成端到端训练。训练过程中冻结教师模型以保证其不被学生模型“拖累”。训练过程中,将 ECG 数据和 CXR 数据分别送入 ECG 分类模型和 CXR 分类模型,得到各自的中间层特征和 ECG 分类结果,进行损失函数计算后梯度反向传播,更新 ECG 分类模型的参数,实现从 CXR 教师模型到 ECG 学生模型的知识迁移。整个训练过程基于 MIMIC-ECG-CXR 数据集,最终得到经过知识蒸馏优化的 ECG 分类模型,实现单模态 ECG 分类性能的提升。

4.2.3 CMKD-FCL 算法框架设计




图 4-1 CMKD-FCL 框架示意图

4.2.3.1 预训练阶段

预训练阶段与第三章保持一致。

4.2.3.2 模型中间特征对比学习构建跨模态知识蒸馏

在基于前文得到的 ECG 和 CXR 两个模态的编码器后，进入第二个训练阶段——基于模型中间特征对比学习构建的跨模态知识蒸馏。

将 CXR 模态的编码器和分类头进行参数冻结，作为教师模型；将 ECG 模型的编码器和分类头加入参数的训练，作为学生模型。由 MIMIC-ECG-CXR 多模态 ECG-CXR 配对数据集获得每一批次配对的 ECG-CXR 数据，分别经各自的编码器和相应的特征映射头 Proj 得到中间层特征，使用基于 KRC 跨模态可靠样本筛选的对比学习知识蒸馏损失函数后进行梯度的反向传播，更新 ECG 模态的编码器和分类头。其中，特征映射头 Proj 和分类头 MLP 均与第三章保持一致。

4.3 自适应难负样本惩罚的全局特征对比学习方法研究

CroMoTEX^[26] (Contrastive Cross-Modal Learning for Infusing Chest X-ray Knowledge into ECGs) 是 Punyamoorthy 等人提出的面向 ECG-CXR 的监督式跨模态对比学习框架, 目标是将 CXR 模态的丰富解剖病理细节知识迁移至 ECG 模态, 最终实现仅使用 ECG 单模态即可实现高性能的心血管疾病诊断。该框架采取三阶段训练流程——预训练、跨模态对比对齐、ECG 分类微调, 充分利用监督信息和难负样本挖掘提升了跨模态知识迁移效果。

在预训练阶段, 与第三章的预训练阶段一致。

在跨模态对比对齐阶段, 使用了一种自适应难负样本惩罚的监督式跨模态对齐损失 $\mathcal{L}_{\text{AHNPSupCMA}}$, 对相似度高但不是正样本对的难负样本赋予更高权重, 强化特征区分度。一个 batch 内, 输入数据为 $\mathcal{D} = \{x_i^e, x_i^c, y_i\}_{i=1}^B$, ECG 投影特征 $z_i^e = g_{\text{ecg}}(f_{\text{ecg}}(x_i^e)) \in \mathbb{R}^d$, CXR 投影特征 $z_i^c = g_{\text{cxr}}(f_{\text{cxr}}(x_i^c)) \in \mathbb{R}^d$, $\mathcal{L}_{\text{AHNPSupCMA}}$ 计算方式如(4-1)所示。其中, 温度参数 $\tau > 0$, 模态类别 $m, n \in \{e, x\}$, 集合 $A(i) = B \setminus \{i\}$, 集合 $P(i) = \{p \in A(i) \mid y_p = y_i\}$, 相似度 $s_{i,a} = (z_i^m)^\top \cdot z_a^n$ 。

$$\begin{aligned} \mathcal{L}_{\text{SupCMA}}^{m,n} &= -\sum_{i=1}^B \frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{\exp(s_{i,p} / \tau)}{\sum_{a \in A(i)} \exp(s_{i,a} / \tau)} \\ \mathcal{L}_{\text{SupCMA}} &= \frac{1}{2} \mathcal{L}_{\text{SupCMA}}^{e,x} + \frac{1}{2} \mathcal{L}_{\text{SupCMA}}^{x,e} \\ \mathcal{L}_{\text{AHNPSupCMA}}^{m,n} &= -\sum_{i=1}^B \frac{1}{|P(i)|} \sum_{p \in P(i)} \log \frac{(1 + \beta \cdot \mathbf{1}_{i=p}) \exp(s_{i,p} / \tau)}{\sum_{a \in A(i)} w_{i,a} \cdot \exp(s_{i,a} / \tau)} \\ \mathcal{L}_{\text{AHNPSupCMA}} &= \frac{1}{2} \mathcal{L}_{\text{AHNPSupCMA}}^{e,x} + \frac{1}{2} \mathcal{L}_{\text{AHNPSupCMA}}^{x,e} \end{aligned} \quad (4-1)$$

其中有三种加权策略: top-k、线性、指数, 动态调整难负样本惩罚力度。作者证明使用 top-k 效果最好。

$$w_{i,a}^{\text{top-k}} = \begin{cases} \alpha, & a \in \text{top-}k\% \text{ similar to } i \\ 1, & \text{otherwise} \end{cases} \quad (4-2)$$

在 ECG 分类微调阶段, 即丢弃映射头, 仅保留 ECG 编码器和分类头 MLP。

尽管 CroMoTEX^[26]验证了跨模态迁移的可行性, 但仅在样本级的全局特征上对齐, 未考虑细粒度的特征关联, 也未针对模态不平衡的噪声干扰设计专门的蒸

馏策略。因此，本章在基于 CroMoTEX^[26]的工作基础上进行改进，进一步提出一种基于特征对比学习的跨模态知识蒸馏技术 CMKD-FCL。




图 4-2 CroMoTEX 框架示意图^[26]

本章的 CMKD-FCL 在跨模态全局对比时，采用 CroMoTEX^[26]中使用的 top-k 自适应难负样本惩罚方法（AHPN），对相似度高但不是正样本对的难负样本赋予更高权重，强化特征区分度。

设一个 batch 内，输入数据为 $\mathcal{D} = \{x_i^e, x_i^c, y_i\}_{i=1}^B$ ，ECG 投影特征 $z_i^e = g_{\text{ecg}}(f_{\text{ecg}}(x_i^e)) \in \mathbb{R}^d$ ，CXR 投影特征 $z_i^c = g_{\text{cxr}}(f_{\text{cxr}}(x_i^c)) \in \mathbb{R}^d$ ，与 Ding 等人^[19]一致的跨模态对齐损失 $\mathcal{L}_{\text{AHPNPSupCMA}}$ 计算方式如(4-4)所示。其中，温度参数 $\tau > 0$ ，模态类别 $m, n \in \{e, x\}$ ，相似度 $s_{i,j} = (z_i^m)^\top \cdot z_j^n$ ， $w_{i,j}^{\text{top-k}}$ 计算方式如(4-5)所示。

$$\mathcal{L}_{\text{CMA}}^{m \rightarrow n} = -\frac{1}{B} \sum_{i=1}^B \log \frac{\exp(s_{i,i} / \tau)}{\sum_j \exp(s_{i,j} / \tau)} \quad (4-3)$$

$$\mathcal{L}_{\text{CMA}} = \frac{1}{2} \mathcal{L}_{\text{CMA}}^{e \rightarrow x} + \frac{1}{2} \mathcal{L}_{\text{CMA}}^{x \rightarrow e}$$

$$\mathcal{L}_{\text{AHNPCMA}}^{m \rightarrow n} = -\frac{1}{B} \sum_{i=1}^B \log \frac{(1+\beta) \cdot \exp(s_{i,i} / \tau)}{\sum_j w_{i,j}^{\text{top-k}} \cdot \exp(s_{i,j} / \tau)} \quad (4-4)$$

$$\mathcal{L}_{\text{AHNPCMA}} = \frac{1}{2} \mathcal{L}_{\text{AHNPCMA}}^{e \rightarrow x} + \frac{1}{2} \mathcal{L}_{\text{AHNPCMA}}^{x \rightarrow e}$$

$$w_{i,j}^{\text{top-k}} = \begin{cases} \alpha, & j \in \text{top-}k\% \text{ similar to } i \\ 1, & \text{otherwise} \end{cases} \quad (4-5)$$




图 4-3 AHNPCMA 计算示意图

4.4 软匹配后期交互 SMLI 的局部对比学习算法设计

现有一些跨模态的局部对比学习的方法^[56]虽然实现了局部区域的语义对齐，但都基于注意力机制网络对齐，同时伴随着高昂的计算开销。而以 FILIP^[28]为代表的后期交互的局部对齐方案，通过损失函数建立一种匹配关系，实现了一种类注意力机制的细粒度语义对齐。但以上方法都基于 Transformer^[1]架构的网络，本章的 CMKD-FCL 的 CXR 编码器却是基于 DenseNet^[57]，无法直接使用。

除此之外，在心脏疾病的诊断中，ECG 信号与 CXR 信号之间应该存在一种多对多的匹配关系，如图 4-4 所示。

因此，本章设计了一种适合本研究的局部对比学习的损失函数，通过分别从 ECG 编码器和 CXR 编码器得到包含多个子区域的中间特征，计算了一种软匹配后

期交互损失函数 SMLI。下面以 ECG 模型到 CXR 模型的映射损失 $\mathcal{L}_{\text{SMLI}}^{e \rightarrow c}$ 为例，推导 $\mathcal{L}_{\text{SMLI}}$ 。




图 4-4 ECG 信号与 CXR 信号的多对多映射关系示意图

设 ECG 和 CXR 的局部特征分别为 $e_i \in [N_e, D]$ 和 $c_i \in [N_c, D]$ ，ECG 样本 i 和 CXR 样本 j 局部特征的样本级相似度矩阵 $(S_{i,j}^{e \rightarrow c})_{\text{sub}} \in [N_e, N_c]$ ，计算如(4-6)所示。

$$(S_{i,j}^{e \rightarrow c})_{\text{sub}} = e_i^\top c_j \quad (4-6)$$

由样本级相似度矩阵可得 softmax^[58]形式的软匹配权重 $(W_{i,j}^{e \rightarrow c})_{\text{sub}}^{n_1, n_2}$ ，计算如(4-7)所示。

$$(W_{i,j}^{e \rightarrow c})_{\text{sub}}^{n_1, n_2} = \frac{\exp\left((S_{i,j}^{e \rightarrow c})_{\text{sub}}^{n_1, n_2} / \tau_1\right)}{\sum_{a=1}^{N_c} \exp\left((S_{i,j}^{e \rightarrow c})_{\text{sub}}^{n_1, a} / \tau_1\right)} \quad (4-7)$$

由 CXR 样本 j 每个局部区域的软匹配权重加权组合，形成一个适配 ECG 对应局部区域的聚合特征 $c_j^{\text{Agg}} \in [N_e, D]$ ，即

$$c_j^{\text{Agg}} = \sum_j (W_{i,j}^{e \rightarrow c})_{\text{sub}} \cdot c_j \quad (4-8)$$

之后，通过 LSE 池化^[59]计算样本级聚合相似度矩阵 $\text{Agg}(e_i, c_j^{\text{Agg}})$ ，计算如(4-9)所示。

$$\begin{aligned} \text{LSE}(x_1, x_2, \tau) &= \log\left(\sum \exp(x_1^\top x_2 / \tau)\right)^\tau \\ \text{Agg}(e_i, c_j^{\text{Agg}}) &= \text{LSE}(e_i, c_j^{\text{Agg}}, \tau_2) \end{aligned} \quad (4-9)$$

最后， $\mathcal{L}_{\text{SMLI}}^{e \rightarrow c}$ 就是基于样本级聚合相似度矩阵 $\text{Agg}(e_i, c_i^{\text{Agg}})$ 计算的 Info-NCE。

$$\mathcal{L}_{\text{SMLI}}^{e \rightarrow c} = -\frac{1}{B} \sum_i \frac{\exp(\text{Agg}(e_i, c_i^{\text{Agg}}) / \tau_3)}{\sum_j \exp(\text{Agg}(e_i, c_j^{\text{Agg}}) / \tau_3)} \quad (4-10)$$

$$\mathcal{L}_{\text{SMLI}} = \frac{1}{2} (\mathcal{L}_{\text{SMLI}}^{e \rightarrow c} + \mathcal{L}_{\text{SMLI}}^{c \rightarrow e}) \quad (4-11)$$




图 4-5 SMLI 计算过程示意图

为了在训练过程中，保证跨模态局部匹配的一致性，即在同一匹配对 ECG 和 CXR 数据中，ECG 到 CXR 的局部对应应该与 CXR 到 ECG 的局部对应保持相似性，因此本章还设计了双向一致性正则化损失，使得 ECG 样本 i 和 CXR 样本 i 局部特征的样本级软匹配权重 $(W_{i,i}^{e \rightarrow c})_{\text{sub}}$ 和 $(W_{i,i}^{c \rightarrow e})_{\text{sub}}$ 具有相似性，计算方式如(4-12)所示。

$$\mathcal{L}_{\text{reg}} = \frac{1}{2} \left[\text{KL} \left((W_{i,i}^{e \rightarrow c})_{\text{sub}}, (W_{i,i}^{c \rightarrow e})_{\text{sub}} \right) + \text{KL} \left((W_{i,i}^{c \rightarrow e})_{\text{sub}}, (W_{i,i}^{e \rightarrow c})_{\text{sub}} \right) \right] \quad (4-12)$$

$$\mathcal{L}_{\text{SMLI}} = \frac{1}{2} (\mathcal{L}_{\text{SMLI}}^{e \rightarrow c} + \mathcal{L}_{\text{SMLI}}^{c \rightarrow e}) + \lambda \mathcal{L}_{\text{reg}} \quad (4-13)$$

4.5 全局与局部对比联合约束的知识蒸馏损失函数设计

对每个匹配的 ECG-CXR 样本对，本章同样使用 KRC 系数进行高质量样本筛选，结合 AHNPCMA 和 SMLI 损失函数，设计了一个基于 KRC 跨模态可靠样本筛选的全局与局部对比联合约束的知识蒸馏损失函数。

最终损失函数的计算方式如(4-14)所示，其中 H 为样本级的 KRC 掩码。

$$\mathcal{L}_{\text{total}} = H \cdot (\lambda_1 \mathcal{L}_{\text{AHNPCMA}} + \lambda_2 \mathcal{L}_{\text{SMLI}}) + \mathcal{L}_{\text{CE}} \quad (4-14)$$




图 4-6 CMKD-FCL 损失函数计算示意图

4.6 实验环境设置和实验结果分析

4.6.1 实验环境设置

本章实验均基于 PyTorch 框架^[47]实现，实验环境设置如表 4-1 所示。CMKD-FCL 预训练阶段与第三章一致，CMKD-FCL 阶段训练时的参数设置如表 4-2 所示，初始学习率为 $1e-4$ ，共训练了 8 个 epoch，采用了 5 轮预热和余弦衰减

策略，batch size 为 64。

表 4-1 CMKD-FCL 软硬件环境

名称	信息	个数
CPU	英特尔 Xeon Gold 6330@2.0GHz 28 核心，56 线程	1
GPU	英伟达 RTX3080Ti 12G GDDR6X	1
内存	镁光 MICRON 64GB DDR4 2933	4
操作系统	Ubuntu 18.04	/
编程语言	python 3.12.13	/
深度学习框架	pytorch 2.10.0+ CUDA13.0	/

表 4-2 CMKD-FCL 训练相关参数设置

阶段	名称	设置值
CMKD-ML 阶段	优化器	AdamW
	初始学习率	1e-4
	训练轮次	8
	学习策略	5 轮预热+余弦衰减
	学习率衰减系数	0.5
	Batch size	64

表 4-3 CMKD-FCL 损失函数超参数设置

损失函数	公式	参数	值
AHNPCMA	(4-4)	β	3.0
	(4-5)	α	5.0
	(4-4)	τ	0.01
SMLI	(4-7)	τ_1	0.1
	(4-9)	τ_2	0.1
	(4-10)	τ_3	1.0
	(4-13)	λ	0.1
最终损失函数	(4-14)	λ_1	0.1
		λ_2	0.1

CMKD-FCL 损失函数中的超参数设置如表 4-3 所示，KRC 部分的参数与第三章一致。

4.6.2 实验结果分析

本章的实验结果分析中的性能指标均使用的是 AUROC。

4.6.2.1 对比实验分析

表 4-4 CMKD-FCL 对比实验结果

	心脏肥大	肺水肿	胸腔积液	Average
ECG_only	0.7271	0.7632	0.7252	0.7385
ResNet-1D	0.7065	0.6842	0.6351	0.6753
ECCL ^[19]	0.7085	0.6787	0.6412	0.6761
BIOT ^[49]	0.7263	0.6945	0.6023	0.6744
SupCon ^[50]	0.7446	0.7764	0.7081	0.7430
Cro-AE ^[51]	0.7215	0.6826	0.6608	0.6883
CroMoTEX ^[26]	0.7516	0.7671	0.7331	0.7506
CMKD-ML	0.7582	0.7999	0.7672	0.7751
	↑ 0.0311	↑ 0.0367	↑ 0.0420	↑ 0.0366
CMKD-FCL	0.7623	0.8047	0.7751	0.7807
	↑ 0.0352	↑ 0.0415	↑ 0.0499	↑ 0.0422
CXR_only	0.8657	0.9231	0.9109	0.8999

为更加全面地评估 CMKD-FCL 的性能水平，本章通过与现有的方法进行的全类别的对比分析，包括仅单模态 ECG 方法、自监督对比训练方法和跨模态训练方法，同时给出了 CXR 单模态能力作为参考标准，结果如表 4-4 所示。

CMKD-FCL 平均 AUROC 数值为 0.7807，ECG_only 基线平均 AUROC 为 0.7385，CMKD-FCL 指标上涨了 0.0422。依托 CXR 教师模型的特征信息迁移，ECG 学生模型的病症分类表现在三个类别上均得到了明显改善，本章的跨模态知识蒸馏方式实现了有效强化单模态模型判别能力。

主流的自监督学习方案，平均 AUROC 区间集中在 0.6744 至 0.7430。本章的 CMKD-FCL 整体表现优于上述各类方法。

而对比跨模态研究方案 CroMoTEX^[26]，CMKD-FCL 在三个类别的诊断任务上

分别实现 0.0107、0.0376、0.0420 的性能提升，整体平均 AUROC 增加 0.0301。相比第三章的 CMKD-ML，CMKD-FCL 在三个类别上分别提升 0.0041、0.0048、0.0079，平均 AUROC 提升了 0.0056，达到了现有方法最优性能。CMKD-FCL 在 CMKD-ML 的基础上，从模型 logits 层面进一步深入至中间特征层面，通过全局对比损失 AHNPCMA 和局部对比损失 SMLI 的联合约束，实现了更精细的跨模态知识迁移，进一步缩小了 ECG 单模态与 CXR 单模态之间的性能差距。

CXR_only 模型平均 AUROC 为 0.8999，CMKD-FCL 平均 AUROC 为 0.7807，二者存在 0.1192 的性能差值。客观来看，ECG 模态的分析能力仍与 CXR 模态存在差距。经过跨模态知识蒸馏优化后，ECG 模型分类精度已满足实际使用需求。结合临床场景分析，ECG 信号采集流程简便、获取成本更低，优化后的 ECG 分析模型更贴合基层医疗与大规模筛查场景，具备良好的落地应用价值。

4.6.2.2 消融实验分析

为验证 CMKD-FCL 中使用的局部对比损失和 KRC 样本筛选机制的对最终性能的贡献，本章设计了消融实验，分别验证了 SMLI 和 KRC 的作用。

表 4-5 CMKD-FCL 消融实验结果

	心脏肥大	肺水肿	胸腔积液	Average
CMKD-FCL				
(no SMLI, no KRC)	0.7616	0.7996	0.7717	0.7776
CMKD-FCL				
(no KRC)	0.7604	0.8036	0.7748	0.7796
CMKD-FCL	0.7623	0.8047	0.7751	0.7807

对比表 4-5 中的 CMKD-FCL(no SMLI, no KRC)和 CMKD-FCL(no KRC)可知，引入 SMLI 后，模型在肺水肿类别上提升 0.0040，在胸腔积液类别上提升 0.0031，平均 AUROC 从 0.7776 提升至 0.7796，提升了 0.0020，但仅在心脏肥大这一类别上略有下降，这有可能是由于局部对齐强制对噪声部分进行的对齐，造成了一定的负面影响。

再对比 CMKD-FCL(no KRC)和 CMKD-FCL 可知，使用了 KRC 后，完整模型在心脏肥大类别上提升 0.0019，在肺水肿类别上提升 0.0011，在胸腔积液类别上提升 0.0003，平均 AUROC 从 0.7796 提升至 0.7807，提升了 0.0011，可以体现出

KRC 筛选的高质量样本在一定程度上弥补了局部对齐中的噪声影响。

综合来看,完整 CMKD-FCL 模型相比仅使用 AHNP 的基线版本(no SMLI, no KRC),平均 AUROC 提升了 0.0031,三个类别均有稳定提升。消融实验表明,KRC 样本筛选机制和 SMLI 局部对比损失两个部分都能为模型性能带来贡献,SMLI 损失函数通过软匹配后期交互机制,建立了 ECG 信号局部区域与 CXR 图像局部区域之间的多对多匹配关系,实现了细粒度的跨模态局部特征对齐,使学生模型能够更精准地学习教师模型在局部区域上的判别知识;而 KRC 又筛选出两个模型预测趋势一致的高质量、高可靠的样本进行蒸馏,过滤噪声样本和跨模态不可靠样本,在一定程度上避免了直接强制性蒸馏带来的负面效果,二者共同构成了 CMKD-FCL 算法的核心竞争力。

4.6.2.3 特征分布可视化分析

为直观展示 CMKD-FCL 蒸馏后 ECG 模型的特征表征能力,本章同样采用 UMAP^[52]降维方法对测试集样本的中间层特征进行可视化分析。分别针对心脏肥大、肺水肿和胸腔积液三个诊断类别,将正样本和负样本的特征投影至二维空间进行展示。

可视化结果表明,经过 CMKD-FCL 跨模态知识蒸馏后,ECG 模型在三个诊断类别上均能学到具有一定区分度的特征表征。正样本和负样本在嵌入空间中呈现出一定程度的分离趋势,说明模型已从 CXR 教师模型中有效迁移了判别性知识,使得 ECG 学生模型的特征空间具备了较好的类别区分能力。




图 4-7 心脏肥大类别的 UMAP 特征图展示 (从左往右依次为单模态 ECG、经 CMKD-FCL 蒸馏后的 ECG 和单模态 CXR)




图 4-8 肺水肿类别的 UMAP 特征图展示（从左往右依次为单模态 ECG、经 CMKD-FCL 蒸馏后的 ECG 和单模态 CXR）




图 4-9 胸腔积液类别的 UMAP 特征图展示（从左往右依次为单模态 ECG、经 CMKD-FCL 蒸馏后的 ECG 和单模态 CXR）

4.7 本章小结

本章针对第三章基于模型 logits 的知识蒸馏方法仅在分类输出层面进行知识迁移、未能充分利用模型中间层丰富特征信息的局限性，提出了一种基于特征对比学习的跨模态知识蒸馏算法——CMKD-FCL，实现了从模型中间特征层面向 CXR 教师模型向 ECG 学生模型的知识迁移，最终实现了 ECG 单模态分类性能的进一步提升。

在算法设计方面，本章在第三章预训练的基础上，从模型的中间特征层面出发，设计了一种基于特征对比学习的跨模态知识蒸馏损失函数。该损失函数融合了三项关键技术：一是采用自适应难负样本惩罚的监督式跨模态全局对比损失 AHNPCMA，对相似度高但不是正样本对的难负样本赋予更高权重，强化特征区分度；二是设计了软匹配后期交互损失 SMLI，通过建立 ECG 信号局部区域与 CXR 图像局部区域之间的多对多匹配关系，实现细粒度的跨模态局部特征对齐；三是沿用第三章的 KRC 跨模态可靠样本筛选机制，过滤噪声样本和不可靠样本，保证蒸馏质量。三者结合构建了完整的全局与局部对比联合约束的知识蒸馏训练框架。

在实验验证方面，本章基于 MIMIC-ECG-CXR 数据集进行了全面的实验分析。

消融实验表明, KRC 样本筛选机制和 SMLI 局部对比损失各自独立地为模型性能带来贡献, 完整 CMKD-FCL 模型的平均 AUROC 达到 0.7807, 相比不含任何改进的基线提升了 0.0031。对比实验表明, CMKD-FCL 在心脏肥大、肺水肿和胸腔积液三个诊断类别上均优于所有对比方法, 相比现有最优跨模态方法 CroMoTEX^[26] 平均 AUROC 提升了 0.0301, 相比第三章的 CMKD-ML 提升了 0.0056, 相比未经蒸馏的 ECG 单模态基线提升了 0.0422。特征分布可视化分析进一步验证了 CMKD-FCL 能够使 ECG 模型学到具有较好类别区分度的特征表征。

综上所述, CMKD-FCL 算法在第三章 CMKD-ML 的基础上进一步从中间特征层面对齐, 通过全局与局部对比学习的联合约束, 实现了更精细、更高效的跨模态知识迁移, 有效提升了 ECG 单模态分类性能, 验证了基于特征对比学习的跨模态知识蒸馏策略在多标签医学诊断任务中的可行性和有效性。

5 总结与展望

5.1 本文主要内容与结论

本文围绕心血管疾病的智能诊断场景下, ECG-CXR 多模态数据融合处理技术展开了研究, 分析了当前 ECG-CXR 跨模态存在模态间语义特征差异大, 诊断分类性能差异大、全局对比学习缺乏细粒度对齐以及跨模态噪声影响知识蒸馏稳定性等核心挑战。针对上述问题, 本文从跨模态知识蒸馏的两类方向出发, 分别提出了基于模型 logits 的跨模态知识蒸馏技术 (CMKD-ML) 和基于特征对比学习的跨模态知识蒸馏技术 (CMKD-FCL), 实现了从高性能 CXR 教师模型向低性能 ECG 学生模型的高效知识迁移, 显著提升了 ECG 单模态的分类性能。各章的主要内容及结论总结如下。

第一章: 绪论。主要分析了本课题的研究背景与意义, 表明当前基于 ECG 数据的早期大规模筛查心血管疾病的智能诊断的重要性, 以及 ECG 信号在基层医疗场景下的优势。其次, 针对面向智能医学诊断的多模态数据融合处理技术系统阐述了从图文领域到医学领域的多模态研究现状, 进一步扩展到跨模态知识蒸馏的国内外研究现状。最后, 总结了当前 ECG-CXR 跨模态处理的核心难题, 提出了本文的研究思路和主要内容。

第二章: 数据集与评价指标。主要说明了本课题开展实验的前期准备工作。首先介绍了本次课题使用的 ECG-CXR 跨模态数据集——MIMIC-ECG-CXR 数据集, 并阐述了其数据来源、数据清洗、模态对其和标签标注的完整流程, 明确本次实验所用的疾病标签——心脏扩大 (Cardiomegaly)、水肿 (Edema) 和胸腔积液 (Pleural Effusion)。最后介绍了时间序列分类任务的常用评价指标, 包括准确率、灵敏度、特异度、精确率、F1 分数和 AUROC, 为后续实验的开展奠定了基础。

第三章: 基于模型 logits 的跨模态知识蒸馏技术。从模型的 logits 输出层面出发, 设计了一种基于模型 logits 的跨模态知识蒸馏技术端到端框架——CMKD-ML。首先使用类似于 SimCLR^[41]的自监督对比学习方式对 ECG 编码器进行预训练, 同时利用分类监督损失对 CXR 编码器进行预训练。在此基础之上, 通过引入解耦知识蒸馏 (DKD) 的思想, 将经典的 KL 散度拆分为目标类知识蒸馏 (TCKD) 和非

目标类知识蒸馏(NCKD)两部分,仅使用NCKD部分并结合监督分类损失;同时引入KRC构建跨模态高质量可靠样本筛选机制。基于MIMIC-ECG-CXR数据集的实验分析可知,CMKD-ML的平均AUROC达到了0.7751,相比于未经蒸馏的ECG单模态基线提升了0.0366,相比于现有最优跨模态方法CroMoTEX^[26]提升了0.0245,验证了CMKD-ML在多标签智能医学诊断任务的有效性。

第四章:基于特征对比学习的跨模态知识蒸馏技术。在第三章预训练的基础上,通过另一个方向——基于模型的中间层特征,设计了一种基于特征对比学习的跨模态知识蒸馏技术——CMKD-FCL。该方法融合了三项关键技术:一是自适应难负样本的跨模态全局对比损失AHNPCMA,对相似度高但不是正样本对的难负样本赋予更高的权重,强化特征的区分度;二是设计了一种软匹配后期交互损失SMLI,通过建立ECG信号局部区域和CXR信号局部区域之间的多对多映射,实现细粒度的跨模态局部对齐;三是沿用第三章中使用的KRC跨模态高质量可靠样本筛选机制,保证蒸馏质量。基于MIMIC-ECG-CXR数据集的实验分析可知,CMKD-FCL的平均AUROC达到了0.7807,相比于未经蒸馏的ECG单模态基线提升了0.0422,相比于现有最优跨模态方法CroMoTEX^[26]提升了0.0301,相比于第三章提出的CMKD-ML进一步提升了0.0056,达到了现有方法的最优性能。

综上所述,本文从模型logits和中间层特征两个层面递进式地提出了两种跨模态知识蒸馏技术,有效解决了ECG-CXR多模态融合中模态差异大、知识传递效率低等问题,实现了从CXR教师模型到ECG学生模型的高效跨模态知识迁移。两种方法均在MIMIC-ECG-CXR数据集上取得了优于现有方法的分类性能,验证了跨模态知识蒸馏在多标签医学诊断任务中的可行性和有效性。为基层医疗和大规模筛查场景下,仅依赖ECG信号即可实现高性能智能诊断提供了技术支撑。

5.2 未来展望

本文提出的两种跨模态知识蒸馏方法虽然在ECG-CXR多模态医学诊断任务上取得了较好的性能,但仍然存在以下方向可以进一步探索和改进。

第一,可以引入更多模态的知识迁移。本文聚焦于ECG和CXR两种模态之间的跨模态知识蒸馏。在实际临床中还有磁共振(CMR)和电子病历描述文本等,未来可以扩展至更多模态的知识蒸馏场景,探索不同异构模态之间的协同知识迁移策略。

第二,可以研究更高效的样本筛选机制。本文采用 KRC 系数进行跨模态可靠样本筛选,虽然取得了一定效果,但 KRC 系数仅衡量了教师模型与学生模型预测排序的一致性,未能充分利用样本级的语义信息。未来可研究结合模型不确定性估计、样本质量评估等多维度信息的自适应样本筛选机制,更精准地识别和过滤不可靠样本,提升蒸馏效率。

第三,可以研究双向蒸馏的高效蒸馏方式。本文的 CMKD-ML 和 CMKD-FCL 均基于 CXR 模态编码器冻结的状态下进行蒸馏,若不进行冻结反而蒸馏效率不高。但目前已有相关研究^[32]开始探索将教师模态也进行参数训练,通过代理机制同时进行双向蒸馏和自蒸馏,可以进一步提高蒸馏效率,甚至可以提升教师模态的分类性能。

参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
- [2] Lu J, Batra D, Parikh D, et al. ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [3] Radford A, Kim J W, Hallacy C, et al. Learning Transferable Visual Models From Natural Language Supervision[C]//Proceedings of the 38th International Conference on Machine Learning. PMLR, 2021: 8748-8763.
- [4] Li J, Selvaraju R, Gotmare A, et al. Align before Fuse: Vision and Language Representation Learning with Momentum Distillation[J]. Advances in neural information processing systems, 2021, 34: 9694-9705.
- [5] Singh A, Hu R, Goswami V, et al. FLAVA: A Foundational Language and Vision Alignment Model[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 15638-15650.
- [6] Guzhov A, Raue F, Hees J, et al. Audioclip: Extending Clip to Image, Text and Audio[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2022: 976-980.
- [7] Wu H H, Seetharaman P, Kumar K, et al. Wav2CLIP: Learning Robust Audio Representations from Clip[C]//ICASSP 2022 - 2022 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). 2022: 4563-4567.
- [8] Liu S, Xu C, Li Y, et al. AG-Fusion: adaptive gated multimodal fusion for 3d object detection in complex scenes[C]//ICASSP 2026-2026 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2026: 10397-10401.
- [9] Li J, Li D, Savarese S, et al. BLIP-2: Bootstrapping Language-Image Pre-training with Frozen Image Encoders and Large Language Models[C]//Proceedings of the 40th International Conference on Machine Learning. PMLR, 2023: 19730-19742.

- [10] Liu H, Li C, Wu Q, et al. Visual Instruction Tuning[J]. Advances in Neural Information Processing Systems, 2023, 36: 34892-34916.
- [11] Bai S, Cai Y, Chen R, et al. Qwen3-vl technical report[J]. arXiv preprint arXiv:2511.21631, 2025.
- [12] Goswami N, Dogra A, Bakshi S, et al. Multimodal Medical Image Fusion: Techniques, Databases, Evaluation Metrics, and Clinical Applications -A Comprehensive Review[J]. The Open Neuroimaging Journal, 2025, 18(1).
- [13] Bavirisetti D P, Kollu V, Gang X, et al. Fusion of MRI and CT images using guided image filter and image statistics[J]. International Journal of Imaging Systems and Technology, 2017, 27(3): 227-237.
- [14] Li Y, Zhao J, Lv Z, et al. Medical image fusion method by deep learning[J]. International Journal of Cognitive Computing in Engineering, 2021, 2: 21-29.
- [15] Huang S C, Shen L, Lungren M P, et al. GLoRIA: A Multimodal Global-Local Representation Learning Framework for Label-efficient Medical Image Recognition[C]//2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, QC, Canada: IEEE, 2021: 3922-3931.
- [16] Hager P, Menten M J, Rueckert D. Best of Both Worlds: Multimodal Contrastive Learning With Tabular and Imaging Data[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 23924-23935.
- [17] King R, Yang T, Mortazavi B J. Multimodal Pretraining of Medical Time Series and Notes[C]//Proceedings of the 3rd Machine Learning for Health Symposium. PMLR, 2023: 244-255.
- [18] Thapa S. MoRE: Multi-modal contrastive pre-training with transformers on X-Rays, ECGs, and radiology/cardiology report[D]. Iowa State University, 2024.
- [19] Ding Z, Hu Y, Li Z, et al. Cross-Modality Cardiac Insight Transfer: A Contrastive Learning Approach to Enrich ECG with CMR Features[C]//Linguraru M G, Dou Q, Feragen A, et al. Medical Image Computing and Computer Assisted Intervention – MICCAI 2024. Cham: Springer Nature Switzerland, 2024: 109-119.
- [20] Vaida M, Huang Z. Multimodal graph neural networks in healthcare: a review of fusion strategies across biomedical domains[J]. Frontiers in Artificial Intelligence,

2026, 8: 1716706.

- [21] Han H, Lian C, Zeng Z, et al. Multimodal multi-instance learning for long-term ECG classification[J]. Knowl. Based Syst., 2023, 270: 110555.
- [22] Chen Y, Huang S, Cheng Y, et al. AimTS: Augmented Series and Image Contrastive Learning for Time Series Classification[C]//2025 IEEE 41st International Conference on Data Engineering (ICDE). 2025: 1952-1965.
- [23] Zhang Y, Jiang H, Miura Y, et al. Contrastive Learning of Medical Visual Representations from Paired Images and Text[C]//Proceedings of the 7th Machine Learning for Healthcare Conference. PMLR, 2022: 2-25.
- [24] Wang Z, Wu Z, Agarwal D, et al. MedCLIP: Contrastive Learning from Unpaired Medical Images and Text[C]//Goldberg Y, Kozareva Z, Zhang Y. Proceedings of the 2022 Conference on Empirical Methods in Natural Language Processing. Abu Dhabi, United Arab Emirates: Association for Computational Linguistics, 2022: 3876-3887.
- [25] Gao Y, Kim S, Austin D E, et al. MEDBind: Unifying Language and Multimodal Medical Data Embeddings[C]//Linguraru M G, Dou Q, Feragen A, et al. Medical Image Computing and Computer Assisted Intervention – MICCAI 2024. Cham: Springer Nature Switzerland, 2024: 218-228.
- [26] Punyamoorthy V, Malusare A, Aggarwal V. Contrastive cross-modal learning for infusing chest x-ray knowledge into ecgs[J]. arXiv preprint arXiv:2506.19329, 2025.
- [27] Zhong Y, Yang J, Zhang P, et al. RegionCLIP: Region-Based Language-Image Pretraining[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 16793-16803.
- [28] Yao L, Huang R, Hou L, et al. FILIP: Fine-grained Interactive Language-Image Pre-Training[C]//International Conference on Learning Representations. 2021.
- [29] 詹光辉. Text-Based Person Re-Identification via Identity and Attribute-Aware Alignment[J]. Computer Science and Application, 2026, 16(02): 348-357.
- [30] Hinton G, Vinyals O, Dean J. Distilling the knowledge in a neural network[J]. stat, 2015, 1050: 9.

- [31] Ebrahimi S, Antoine K, Carlo C, et al. Fitnets: Hints for thin deep nets[C]//International Conference on Learning Representations. 2015.
- [32] Huo F, Xu W, Guo J, et al. C² KD: Bridging the Modality Gap for Cross-Modal Knowledge Distillation[C]//2024 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Seattle, WA, USA: IEEE, 2024: 16006-16015.
- [33] Zhao H, Zhang Q, Zhao S, et al. SimDistill: Simulated Multi-Modal Distillation for BEV 3D Object Detection[J]. Proceedings of the AAAI Conference on Artificial Intelligence, 2024, 38(7): 7460-7468.
- [34] Li H, Yang P, Chen J, et al. MST-Distill: Mixture of Specialized Teachers for Cross-Modal Knowledge Distillation[C]//Proceedings of the 33rd ACM International Conference on Multimedia. Dublin Ireland: ACM, 2025: 1588-1597.
- [35] Xie R, Xu Y, Sanguinetti G. Information-theoretic criteria for knowledge distillation in multimodal learning[J]. arXiv preprint arXiv:2510.13182, 2025.
- [36] Johnson A E W, Bulgarelli L, Shen L, et al. MIMIC-IV, a freely accessible electronic health record dataset[J]. Scientific Data, 2023, 10(1): 1.
- [37] Johnson A, Lungren M, Peng Y, et al. MIMIC-CXR-JPG - chest radiographs with structured labels[DS/OL]. PhysioNet. <https://physionet.org/content/mimic-cxr-jpg/>.
- [38] Liu F, Liu C, Zhao L, et al. An Open Access Database for Evaluating the Algorithms of Electrocardiogram Rhythm and Morphology Abnormality Detection[J]. Journal of Medical Imaging and Health Informatics, 2018, 8(7): 1368-1373.
- [39] Wagner P, Strodthoff N, Bousseljot R D, et al. PTB-XL, a large publicly available electrocardiography dataset[J]. Scientific Data, 2020, 7(1): 154.
- [40] Pearson K. On the theory of contingency and its relation to association and normal correlation: Vol. 1[M]. Cambridge University Press, 1904.
- [41] Chen T, Kornblith S, Norouzi M, et al. A Simple Framework for Contrastive Learning of Visual Representations[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020: 1597-1607.
- [42] Cohen J P, Viviano J D, Bertin P, et al. TorchXRyVision: A library of chest X-ray datasets and models[C]//Proceedings of The 5th International Conference on

- Medical Imaging with Deep Learning. PMLR, 2022: 231-249.
- [43] Gopal B, Han R, Raghupathi G, et al. 3KG: Contrastive Learning of 12-Lead Electrocardiograms using Physiologically-Inspired Augmentations[C]//Proceedings of Machine Learning for Health. PMLR, 2021: 156-167.
- [44] Oord A van den, Li Y, Vinyals O. Representation learning with contrastive predictive coding[J]. arXiv preprint arXiv:1807.03748, 2018.
- [45] Zhao B, Cui Q, Song R, et al. Decoupled Knowledge Distillation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 11953-11962.
- [46] Forthofer R N, Lehnen R G. Rank Correlation Methods[M]//Forthofer R N, Lehnen R G. Public Program Analysis: A New Categorical Data Approach. Boston, MA: Springer US, 1981: 146-163.
- [47] Paszke A, Gross S, Massa F, et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library[J]. Advances in Neural Information Processing Systems, 2019, 32.
- [48] Loshchilov I, Hutter F. Decoupled Weight Decay Regularization[C]//International Conference on Learning Representations. 2018.
- [49] Yang C, Westover M, Sun J. BIOT: Biosignal Transformer for Cross-data Learning in the Wild[J]. Advances in Neural Information Processing Systems, 2023, 36: 78240-78260.
- [50] Khosla P, Teterwak P, Wang C, et al. Supervised Contrastive Learning[J]. Advances in Neural Information Processing Systems, 2020, 33: 18661-18673.
- [51] Radhakrishnan A, Friedman S F, Khurshid S, et al. Cross-modal autoencoder framework learns holistic representations of cardiovascular state[J]. Nature Communications, 2023, 14(1): 2436.
- [52] McInnes L, Healy J, Saul N. UMAP: Uniform Manifold Approximation and Projection[J]. Journal of Open Source Software, 2018, 3(29).
- [53] Hjelm R D, Fedorov A, Lavoie-Marchildon S, et al. Learning deep representations by mutual information estimation and maximization[C]//International Conference

on Learning Representations. 2018.

- [54] Wang T, Isola P. Understanding Contrastive Representation Learning through Alignment and Uniformity on the Hypersphere[C]//Proceedings of the 37th International Conference on Machine Learning. PMLR, 2020: 9929-9939.
- [55] Liu T, Chen C, Yang X, et al. Rethinking Knowledge Distillation With Raw Features for Semantic Segmentation[C]//Proceedings of the IEEE/CVF Winter Conference on Applications of Computer Vision. 2024: 1155-1164.
- [56] Wang F, Zhou Y, Wang S, et al. Multi-Granularity Cross-modal Alignment for Generalized Medical Visual Representation Learning[J]. Advances in Neural Information Processing Systems, 2022, 35: 33536-33549.
- [57] Huang G, Liu Z, van der Maaten L, et al. Densely Connected Convolutional Networks[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2017: 4700-4708.
- [58] Bridle J. Training Stochastic Model Recognition Algorithms as Networks can Lead to Maximum Mutual Information Estimation of Parameters[J]. Advances in Neural Information Processing Systems, 1989, 2.
- [59] Boureau Y L, Ponce J, LeCun Y. A Theoretical Analysis of Feature Pooling in Visual Recognition[C]//Proceedings of the 27th international conference on machine learning (ICML-10). 2010: 111-118.